

Knowledge Distillation Berbasis Teacher-Assistant untuk Model Ringan WasteNet pada Klasifikasi Citra Sampah TrashNet



Mahasiswa

Hamza Pratama
4611422068



Program

S1 Teknik Informatika
FMIPA Universitas Negeri
Semarang - 2026

Masalah utama: akurasi perlu bertemu efisiensi

Pemilahan sampah manual masih rentan tidak konsisten, sementara CNN akurat sering terlalu berat untuk smart bin atau edge device.

Kebutuhan aplikasi

Klasifikasi cepat untuk cardboard, glass, metal, paper, plastic, dan trash.

Kendala deployment

Model besar membutuhkan komputasi tinggi, tidak ideal untuk perangkat terbatas.

Solusi riset

Knowledge distillation mentransfer dark knowledge dari teacher ke student ringan.

Celah riset: capacity gap pada student sangat kecil

Penelitian terdahulu seperti Focus-RCNet melaporkan akurasi sekitar 92% pada TrashNet dengan KD dari EfficientNet-B4. Namun, fokusnya belum pada perbandingan sistematis kapasitas teacher untuk student ultra-ringan.

Kebaruan yang diuji

- Menggunakan WasteNet-128K dan WasteNet-256K sebagai target student ringan.
- Membandingkan large-teacher, teacher-assistant, dan self-distillation secara terkontrol.
- Menggunakan dua ruang label: K6 dan K5 tanpa kelas trash.
- Memvalidasi selisih performa dengan uji statistik.

Rumusan masalah dan tujuan penelitian

-  **01** Bagaimana membangun WasteNet ringan untuk klasifikasi citra sampah TrashNet dengan KD?

-  **02** Bagaimana pengaruh kapasitas teacher terhadap performa student WasteNet?

-  **03** Apakah performa model berbeda signifikan dibanding baseline tanpa KD?

Tujuan akhirnya adalah menentukan strategi distilasi paling efektif untuk student berkapasitas kecil pada klasifikasi sampah.

Dataset: TrashNet sebagai benchmark utama

2.527

citra berlabel (2.521
dipakai setelah dedup)

6

kelas: cardboard,
glass, metal, paper,
plastic, trash

K6 / K5


dua ruang label untuk
menguji pengaruh
kelas trash

70/15/15

split train, validation,
test secara stratified

Kelas trash bersifat heterogen dan memiliki jumlah citra paling sedikit, sehingga proposal menguji skema K5 untuk melihat konsistensi efektivitas distilasi.

Alur & strategi distilasi



■ **TA-KD** — Focus-RCNet (dilatih CE) → WasteNet • asisten berperan sebagai guru, bukan rantai terdistilasi

■ **Direct KD** (vanilla / Hinton) — EfficientNet-B4 → WasteNet

■ **Self-distillation** — WasteNet → WasteNet (Born-Again)

$$L_{KD} = (1 - \alpha) \cdot L_{CE} + \alpha \cdot T^2 \cdot D_{KL}(p_{teacher} \parallel p_{student})$$
 • semua strategi = KD berbasis response/logits (bukan feature-based)

Skenario pengujian model

R1-R9 membentuk benchmark dari baseline, direct KD, teacher-assistant, hingga self-distillation; R10-R11 adalah ablasi komponen arsitektur WasteNet.

Kode	Student	Guru soft-label	Peran
R1	EfficientNet-B4	-	Guru besar / batas atas
R2	Focus-RCNet	-	Asisten menengah
R3	WasteNet-128K	-	Baseline 128K
R4	WasteNet-128K	EfficientNet-B4	Direct KD
R5	WasteNet-128K	Focus-RCNet	TA-KD 128K
R6	WasteNet-256K	-	Baseline 256K
R7	WasteNet-256K	EfficientNet-B4	Direct KD
R8	WasteNet-256K	Focus-RCNet	TA-KD 256K
R9	WasteNet-256K	WasteNet-256K gen. sebelumnya	Self-distillation
R10	WasteNet-128K	-	Ablasi komponen arsitektur
R11	WasteNet-256K	-	Ablasi komponen arsitektur

Hasil: tangga performa R1–R9

Akurasi uji, rata-rata $\pm$ simpangan baku dari 5 seed. Student terbaik = R8.

Kode	Model	Peran / strategi	K6 (6 kelas)	K5 (5 kelas)
R1	EfficientNet-B4 (17,56 jt)	Guru besar — batas atas	$0,9446 \pm 0,0070$	$0,9581 \pm 0,0048$
R2	Focus-RCNet (520,6 rb)	Asisten menengah	$0,8507 \pm 0,0164$	$0,8737 \pm 0,0152$
R3	WasteNet-128K	Baseline CE (floor)	$0,7652 \pm 0,0204$	$0,8067 \pm 0,0200$
R4	WasteNet-128K	Direct KD $\leftarrow$ guru besar	$0,7646 \pm 0,0127$	$0,8061 \pm 0,0181$
R5	WasteNet-128K	TA-KD $\leftarrow$ asisten	$0,7578 \pm 0,0322$	$0,8117 \pm 0,0200$
R6	WasteNet-256K	Baseline CE (floor)	$0,7784 \pm 0,0128$	$0,7994 \pm 0,0259$
R7	WasteNet-256K	Direct KD $\leftarrow$ guru besar	$0,7736 \pm 0,0178$	$0,8056 \pm 0,0156$
R8	WasteNet-256K	TA-KD $\leftarrow$ asisten	$0,7873 \pm 0,0089$	$0,8235 \pm 0,0107$
R9	WasteNet-256K	Self-KD (BAN)	$0,7831 \pm 0,0105$	$0,8134 \pm 0,0109$



Kenaikan R8 hanya bermakna dibanding kontrol berpasangannya (slide berikut), bukan dibanding baris lain di tabel ini.

Bukti utama: TA-KD unggul di setiap seed

Kontrol berpasangan R8 vs R8-CE — dua lengan identik, bedanya hanya KD nyala/mati.

R8 (WasteNet-256K): setiap seed naik saat distilasi asisten dinyalakan

Satu garis = satu seed. Split, konfigurasi, dan inisialisasi identik; yang berbeda hanya KD nyala/mati.



Wilcoxon p = 0,062 di kedua skema label — itu nilai dua sisi TERKECIL yang mungkin untuk n = 5, jadi hasil terkuat yang bisa dicapai uji tersebut.

Capacity gap: kapasitas guru yang menentukan

Lima uji berpasangan pada skema K6, sumbu-y absolut sama di kelima panel.

Lima uji berpasangan (K6) — hanya guru menengah yang konsisten menaikkan setiap seed

Biru = seed naik, merah = seed turun. Lengan yang wash memberi pola acak; R8 satu-satunya yang 5/5 naik dan signifikan.




Guru besar → wash • guru sekapasitas (self-KD) → wash • asisten menengah → menang.

Jadwal pelatihan bukan penentu: two-stage dengan guru besar tetap wash (R2.2). Yang menentukan adalah identitas guru.


R8: di mana TA-KD menolong

$\Delta F1$ per kelas = TA-KD (R8) – kontrol CE, rata-rata 5 seed (pp)

K6 — 6 kelas



K5 — 5 kelas (tanpa trash)



Gain terkonsentrasi di trio kelas tersulit (glass, metal, plastic) — bukti transfer dark knowledge, bukan noise. Kelas trash (K6) justru sedikit turun → sebab K5 menunjukkan gain lebih bersih.

Ablasi komponen arsitektur WasteNet

40 run (4 konfigurasi × 5 seed × 2 varian), skema K6. Baseline dilatih ulang di notebook yang sama agar konfigurasinya terbukti identik.

Varian	Parameter	Akurasi uji	Δ vs baseline (paired-t)
WasteNet-128K — baseline	128.086	0,7689 ± 0,0172	—
aktivasi SiLU → ReLU	128.086	0,7156 ± 0,0193	−5,33 pp (p = 0,004)
expand ratio 2,0 → 1,0	45.638	0,7689 ± 0,0198	+0,00 pp (p = 1,000)
tanpa hidden layer classifier	122.870	0,7646 ± 0,0192	−0,42 pp (p = 0,634)
WasteNet-256K — baseline	256.002	0,7694 ± 0,0164	—
aktivasi SiLU → ReLU	256.002	0,7873 ± 0,0223	+1,79 pp (p = 0,268)
tanpa koneksi residual	256.002	0,7662 ± 0,0130	−0,32 pp (p = 0,702)
expand ratio 2,5 → 1,0	64.206	0,7689 ± 0,0091	−0,05 pp (p = 0,918)

Aktivasi = satu-satunya komponen yang berpengaruh nyata, dan hanya saat kapasitas langka.

Di 256K tidak ada komponen tunggal yang signifikan → kenaikan TA-KD tidak bisa dijelaskan oleh kekhususan arsitektur, melainkan berasal dari cara pelatihan.

Simpulan

-  **01 WasteNet ringan berhasil dibangun dan dilatih dengan knowledge distillation**
Dua varian 128K (≈ 51 MFLOPs) dan 256K (≈ 84 MFLOPs); student terbaik mencapai 0,7873 (K6) dan 0,8235 (K5).
-  **02 Kapasitas guru menentukan keberhasilan distilasi**
Guru besar dan guru berkapasitas sama tidak menolong; hanya asisten menengah yang menaikkan student — dan hanya ketika kapasitas student memadai (256K).
-  **03 Peningkatan tersebut signifikan secara statistik**
+1,00 pp (K6, $p = 0,024$) dan +1,40 pp (K5, $p = 0,045$), unggul pada 5/5 seed, dikonfirmasi McNemar pada K5 ($p = 0,014$).
-  **04 Ablasi: aktivasi kritis hanya saat kapasitas langka**
SiLU $\rightarrow$ ReLU menurunkan 128K sebesar 5,33 pp ($p = 0,004$), sedangkan 256K tahan terhadap seluruh ablasi komponen.

Keterbatasan dan saran

Ditulis terbuka di BAB 4 dan BAB 5; keduanya membatasi tafsir hasil 128K.

Asisten belum benar-benar “menengah” bagi student 128K

Focus-RCNet (520,6 rb) berjarak $2,03\times$ terhadap WasteNet-256K — lengan yang menang — tetapi $4,06\times$ terhadap WasteNet-128K. Hasil 128K dibaca “belum ditemukan asistennya”, bukan “128K tidak bisa didistilasi”.

Hyperparameter lengan 128K belum sepadan

Learning rate dan resolusi asisten pada lengan 128K mengikuti uji pendahuluan skema K5, sehingga simpulan untuk 128K belum dapat dipisahkan sepenuhnya dari pengaruh hyperparameter.

Saran lanjutan

Uji asisten berparameter lebih kecil daripada Focus-RCNet untuk student 128K; perbesar jumlah data dan seed; uji langsung pada perangkat tepi untuk memvalidasi klaim efisiensi.

Terima kasih

Terbuka untuk pertanyaan, saran, dan masukan dari dewan penguji.



Mahasiswa

Hamza Pratama
4611422068



Program

S1 Teknik Informatika
FMIPA Universitas Negeri Semarang -
2026

Protokol data & anti-leakage

CADANGAN

Protokol data

- TrashNet — 2.527 citra, 6 kelas, imbalanced (trash 137 ... paper 594).
- Split dikunci di Notebook R0, sebelum training apa pun.
- Satu manifest per seed, dipakai identik oleh semua model → perbandingan adil.
- Stratified 70/15/15; 5 seed: 42, 123, 777, 2026, 3407.
- Dedup SHA-256: 6 duplikat label-konflik dibuang sebelum split (2.527 → 2.521); duplikat label-sama = 0.

Jaminan anti-leakage

- `validate_split()` meng-assert nol irisan train/val/test — guard otomatis.
- Augmentasi hanya di train; val/test tidak pernah diaugmentasi.
- Normalisasi memakai statistik ImageNet tetap, bukan dihitung dari data.
- Test set tidak dipakai memilih model/epoch/T/ α ; tuning pilot hanya di val seed 42.
- Imbalance ditangani via macro-F1 + confusion matrix + ablasi K5, bukan resampling.

Cadangan — ringkasan uji efek KD

CADANGAN

Uji efek KD (paired, 5 seed)	K6: Δ akurasi (p)	K5: Δ akurasi (p)
Direct KD $\rightarrow$ 256K (R7 – R6)	–0,5pp (p=0,68)	+0,6pp (p=0,68)
TA-KD $\rightarrow$ 128K (R5)	–0,7pp (p=0,20)	–0,5pp (p=0,23)
TA-KD $\rightarrow$ 256K (R8) ★	+1,0pp (p=0,024) • 5/5	+1,4pp (p=0,045) • 5/5
Self-KD $\rightarrow$ 256K (R9, BAN)	+0,5pp (p=0,51)	+1,4pp (p=0,38)

Hanya TA-KD 256K (R8) yang menang & konsisten 5/5 seed.

- Guru besar (EfficientNet-B4) langsung ke student $\rightarrow$ wash (R4/R7): gejala capacity gap.
- Assistant menengah menolong hanya saat student cukup besar $\rightarrow$ R8 = student terbaik: 78,7% (K6) / 82,4% (K5).
- Self-distillation (BAN, R9) directional/wash $\rightarrow$ penentu: kapasitas guru harus menengah, bukan besar atau sama.

Batas atas guru EfficientNet-B4: 94,5% (K6) / 95,8% (K5). Sumber angka: hasil uji pada test set, rata-rata 5 seed.

Cadangan — tiga uji statistik dan unit analisisnya

CADANGAN

Paired t-test

unit: seed (n = 5)

Membandingkan selisih di dalam pasangan seed yang sama. Sumber utama nilai p pada tabel hasil.

Wilcoxon signed-rank

unit: seed (n = 5)

Pendamping nonparametrik, tanpa asumsi normalitas selisih. Dengan $n = 5$, p dua sisi terkecil yang mungkin = 0,0625.

McNemar

unit: sampel uji · koreksi kontinuitas

Membandingkan pola benar-salah per citra pada data uji yang sama, digabung dari 5 seed.

Tabel kontingensi McNemar untuk R8 (digabung 5 seed)

Skema	b: TA-KD benar, kontrol salah	c: TA-KD salah, kontrol benar	χ^2 (koreksi)	p	n
K6 (6 kelas)	64	45	2,97	0,085	1.895
K5 (5 kelas)	60	35	6,06	0,014	1.790

Dilaporkan apa adanya: bukti terkuat ada di K5.

K6 searah dan konsisten 5/5 seed pada uji antar-seed ($p = 0,024$), tetapi pada level sampel belum melewati $\alpha = 0,05$. Kelas trash yang heterogen — satu-satunya kelas yang F1-nya turun di K6 — menjelaskan selisih ini.



Cadangan — mengapa memakai uji berpasangan

CADANGAN

Data yang sama dibaca dua cara: rata-rata $\pm$ sd, lalu selisih berpasangan per seed.

Data yang sama, dua cara membaca — kenapa uji berpasangan yang dipakai

Variasi antar-seed besar (sd $\approx$ 0,9 pp), tetapi selisih dalam seed konsisten — itulah yang diuji paired t-test.



Simpangan baku antar-seed ($\pm$ 0,89 pp) berasal dari perbedaan split per seed, bukan dari efek KD. Desain berpasangan menghilangkan sumber variasi itu — karena itulah uji yang dipakai adalah uji berpasangan.

Cadangan — ablasi: selisih per seed

CADANGAN

Δ akurasi uji terhadap baseline internal masing-masing studi,urut seed 42 / 123 / 777 / 2026 / 3407.

Varian	Δ per seed (pp)	Menang	Sifat
128K SiLU $\rightarrow$ ReLU	-2,4 · -4,7 · -5,3 · -7,9 · -6,3	0/5	bebas parameter (bersih)
128K expand 2,0 $\rightarrow$ 1,0	+1,6 · -2,6 · +2,4 · -4,5 · +3,2	3/5	parameter -82.448
128K tanpa hidden layer	-1,1 · -1,3 · -2,1 · -0,3 · +2,6	1/5	parameter -5.216
256K SiLU $\rightarrow$ ReLU	+5,5 · -0,3 · -2,4 · +3,4 · +2,6	3/5	bebas parameter (bersih)
256K tanpa residual	+1,1 · -1,6 · -2,6 · +0,3 · +1,3	3/5	bebas parameter (bersih)
256K expand 2,5 $\rightarrow$ 1,0	+1,1 · -1,3 · -1,1 · +0,8 · +0,3	3/5	parameter -191.796

Hanya ReLU pada 128K yang konsisten: kalah di seluruh seed.

Varian expand dan hidden-layer mengubah jumlah parameter, sehingga efeknya rancu antara komponen dan kapasitas mentah — jumlah parameter selalu dilaporkan berdampingan. Aktivasi dan residual bebas parameter, jadi perbandingannya bersih. Residual tidak diablasi pada 128K karena di sana tidak ada koneksi residual yang aktif.

Cadangan — arsitektur dan efisiensi WasteNet

CADANGAN

Susunan arsitektur

CNN ringan yang disusun dari blok depthwise-separable dan inverted residual, mengadopsi prinsip efisiensi MobileNet dan EfficientNet. Kernel yang dipakai hanya 3×3 untuk konvolusi spasial (stem dan depthwise) serta 1×1 untuk pencampuran antar-kanal (expand dan project). Dua varian: 128K dan 256K.

Kejelasan nama

Nama “WasteNet” juga dipakai White dkk. (2020) untuk model berbasis DenseNet dengan puluhan juta parameter — model yang berbeda, hanya kebetulan senama. Tidak ada publikasi yang memakai penamaan WasteNet-128K/-256K.

Model	Parameter	MACs @160×160	FLOPs	Akurasi K6
WasteNet-128K	128.086	≈ 25,6 juta	≈ 51 juta	0,7652
WasteNet-256K	256.002	≈ 41,8 juta	≈ 84 juta	0,7873 (R8)
Focus-RCNet (Zheng dkk., 2023)	525.802	—	≈ 419 juta	0,8507 *

WasteNet-256K ≈ separuh parameter dan ≈5× lebih sedikit FLOPs daripada Focus-RCNet.

Jumlah parameter = bobot yang dipelajari + bias + parameter γ dan β pada BatchNorm; fungsi aktivasi dan koneksi residual tidak menambah parameter.

* Angka Focus-RCNet adalah hasil reimplementasi pada protokol ini; penulis aslinya melaporkan 0,92 dengan protokol dan augmentasi yang berbeda.

Cadangan — protokol validasi silang berulang

CADANGAN

Menjawab usulan penambahan k-fold cross validation.

Yang dijalankan

5× hold-out berulang bertingkat 70/15/15 — 1.764 latih / 378 validasi / 379 uji dari 2.521 citra — dengan pemisahan yang BERBEDA pada setiap seed (42, 123, 777, 2026, 3407). Ini adalah repeated / Monte-Carlo cross validation.

Mengapa itu memadai

Manfaat inti k-fold adalah estimasi yang tidak bergantung pada satu pemisahan yang kebetulan menguntungkan. Protokol ini sudah memberikan manfaat tersebut, dengan lima partisi independen.

Dukungan metodologis

Dietterich (1998) — yang disitasi di dalam skripsi — justru memperingatkan bahwa k-fold yang dipadukan paired t-test memiliki Type I error yang meningkat, dan menganjurkan McNemar atau 5×2cv. Penelitian ini memakai keduanya: uji antar-seed dan McNemar per sampel.

Cadangan — capacity gap pada skema 5 kelas


CADANGAN

Pengulangan analisis yang sama pada ruang label K5 sebagai uji ketahanan.


Lima uji berpasangan (K5) — hanya guru menengah yang konsisten menaikkan setiap seed

Biru = seed naik, merah = seed turun. Lengan yang wash memberi pola acak; R8 satu-satunya yang 5/5 naik dan signifikan.


Direct KD 128K
 $\Delta -0,06$ pp · 3/5 · p = 0,962




TA-KD 128K
 $\Delta -0,50$ pp · 1/5 · p = 0,233




Direct KD 256K
 $\Delta +0,61$ pp · 4/5 · p = 0,678



Self-KD 256K (BAN)
 $\Delta +1,40$ pp · 4/5 · p = 0,378



TA-KD 256K
 $\Delta +1,40$ pp · 5/5 · p = 0,045



Pola yang sama berulang: hanya asisten menengah yang unggul 5/5 seed.

Catatan jujur: pada lengan TA-KD 128K terdapat satu seed yang hasilnya identik (garis abu-abu), sehingga komposisinya 1 naik, 3 turun, 1 seri. Self-KD (R9) di K5 berselisih +1,40 pp — sama besar dengan R8 — tetapi hanya 4/5 dan p = 0,378.

Cadangan — penyimpangan dari Mirzadeh dkk.

CADANGAN

Bagaimana asisten dilatih, dan mengapa pilihan itu tidak menentukan hasil.

Mirzadeh dkk. (2020)

Asisten lebih dahulu didistilasi dari guru besar, lalu asisten itu mendistilasi student — rantai bertingkat.

Penelitian ini

Asisten (Focus-RCNet) dilatih dengan cross-entropy, lalu menjadi guru bagi student. Yang diadopsi adalah gagasan intinya: guru berkapasitas menengah sebagai jembatan.

Yang dibandingkan	Asisten dilatih CE	Asisten terdistilasi	Selisih (paired-t)
Akurasi asisten — K6	$0,8507 \pm 0,0164$	$0,8554 \pm 0,0231$	+0,47 pp (p = 0,62)
Akurasi asisten — K5	$0,8737 \pm 0,0152$	$0,8732 \pm 0,0135$	−0,06 pp (p = 0,97)
Student 256K / R8 — K6	$0,7873 \pm 0,0089$	0,7884	+0,11 pp (p = 0,83)
Student 128K / R5 — K6	$0,7578 \pm 0,0322$	0,7763	+1,85 pp (p = 0,07)

Pilihan ini tidak menciptakan kemenangan R8: pada lengan 256K selisihnya hanya 0,11 poin persen, p = 0,83.

Varian dua tahap (R2.2) juga tidak signifikan, p = 0,77 di kedua skema label. Pada student 128K rantai penuh memang sedikit lebih tinggi, tetapi belum signifikan (4/5 seed, p = 0,07) dan lengan itu justru lengan yang keterbatasan hyperparameter-nya sudah saya akui.