



**KNOWLEDGE DISTILLATION BERBASIS TEACHER-ASSISTANT
UNTUK MODEL RINGAN WASTENET PADA KLASIFIKASI CITRA
SAMPAH TRASHNET**

Skripsi

diajukan sebagai salah satu syarat untuk memperoleh gelar
Sarjana Komputer

oleh

Hamza Pratama

4611422068

**PROGRAM STUDI SARJANA TEKNIK INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS NEGERI SEMARANG
SEMARANG, 2026**



PERNYATAAN SIAP SEMINAR PROPOSAL SKRIPSI

Yang bertanda tangan di bawah ini

Nama : Kholiq Budiman, S.Pd., M.Kom.

NIP : 199209242019031013

Sebagai Pembimbing skripsi mahasiswa:

Nama : Hamza Pratama

NIM : 4611422068

Prodi : Teknik Informatika

Topik : *Knowledge Distillation*

Menyatakan bahwa proposal skripsi mahasiswa tersebut di atas telah siap untuk diseminarkan.

Semarang, 30 Juni 2026

Pembimbing,

Kholiq Budiman, S.Pd., M.Kom.

NIP 199209242019031013

NIP 199209242019031013

ABSTRAK

Pratama, Hamza. 2026. Knowledge Distillation Berbasis Teacher-Assistant untuk Model Ringan WasteNet pada Klasifikasi Citra Sampah TrashNet. Skripsi, Program Studi Sarjana Teknik Informatika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Semarang. Pembimbing Kholiq Budiman, S.Pd., M.Kom.

Kata Kunci: Knowledge Distillation, Teacher Assistant, Capacity Gap, Klasifikasi Citra Sampah, TrashNet, Model Ringan.

Klasifikasi citra sampah pada perangkat dengan sumber daya terbatas memerlukan model yang sangat ringan, namun model berukuran kecil umumnya sulit mencapai akurasi yang memadai. Knowledge distillation lazim digunakan untuk mengatasi persoalan tersebut, tetapi efektivitasnya tidak terjamin ketika selisih kapasitas antara guru dan student terlalu besar atau dikenal sebagai capacity gap. Penelitian ini menguji pengaruh kapasitas guru terhadap keberhasilan distilasi pada model ringan WasteNet yang disusun dari blok konvolusi depthwise-separable dengan struktur inverted residual, dalam dua varian kapasitas yaitu WasteNet-128K dengan 128.086 parameter dan WasteNet-256K dengan 256.002 parameter. Tiga jenis guru dibandingkan, yaitu guru besar EfficientNet-B4, asisten berkapasitas menengah Focus-RCNet, dan guru berkapasitas sama melalui skema self-distillation Born-Again Networks. Data yang digunakan adalah TrashNet sebanyak 2.521 citra yang diuji pada dua skema label, yaitu enam kelas dan lima kelas. Setiap skenario dilatih menggunakan lima seed dengan pembagian data 70:15:15 yang berbeda pada setiap seed, kemudian dibandingkan terhadap kontrol berpasangan melalui uji t berpasangan, uji Wilcoxon, dan uji McNemar. Hasil penelitian menunjukkan bahwa distilasi langsung dari guru besar tidak memberikan perbaikan, sedangkan self-distillation hanya menghasilkan perbaikan yang tidak signifikan. Sebaliknya, distilasi melalui asisten berkapasitas menengah meningkatkan akurasi WasteNet-256K sebesar 1,00 poin persentase pada skema enam kelas dengan p sebesar 0,024 dan 1,40 poin persentase pada skema lima kelas dengan p sebesar 0,045, serta unggul pada seluruh seed yang diuji. Model terbaik mencapai akurasi 0,7873 dengan beban komputasi sekitar 84 juta FLOPs dan mempertahankan sekitar 83 persen akurasi guru besarnya menggunakan parameter sekitar 69 kali lebih sedikit. Penelitian ini menyimpulkan bahwa guru yang efektif bukanlah guru yang paling besar, melainkan guru berkapasitas menengah, dan keberhasilan distilasi juga menuntut kapasitas student yang memadai.

ABSTRACT

Pratama, Hamza. 2026. Teacher-Assistant Based Knowledge Distillation for a Lightweight WasteNet Model on TrashNet Waste Image Classification. Undergraduate Thesis, Informatics Engineering Study Program, Faculty of Mathematics and Natural Sciences, Universitas Negeri Semarang. Supervisor: Kholiq Budiman, S.Pd., M.Kom.

Keywords: Knowledge Distillation, Teacher Assistant, Capacity Gap, Waste Image Classification, TrashNet, Lightweight Model.

Waste image classification on resource-constrained devices requires extremely lightweight models, yet small models generally struggle to reach adequate accuracy. Knowledge distillation is commonly used to address this problem, but its effectiveness is not guaranteed when the capacity difference between the teacher and the student is too large, a condition known as the capacity gap. This study examines how teacher capacity affects distillation success on a lightweight WasteNet model built from depthwise-separable convolution blocks with an inverted residual structure, in two capacity variants: WasteNet-128K with 128,086 parameters and WasteNet-256K with 256,002 parameters. Three types of teachers are compared, namely the large teacher EfficientNet-B4, the mid-capacity assistant Focus-RCNet, and a same-capacity teacher through Born-Again Networks self-distillation. The dataset is TrashNet, consisting of 2,521 images evaluated under two label schemes, six classes and five classes. Every scenario is trained with five seeds using a 70:15:15 split that differs per seed, then compared against a paired control using a paired t-test, the Wilcoxon test, and McNemar's test. The results show that direct distillation from the large teacher yields no improvement, while self-distillation produces only a non-significant improvement. In contrast, distillation through the mid-capacity assistant improves WasteNet-256K accuracy by 1.00 percentage point on the six-class scheme with $p = 0.024$ and by 1.40 percentage points on the five-class scheme with $p = 0.045$, winning on all tested seeds. The best model reaches 0.7873 accuracy with approximately 84 million FLOPs and retains about 83 percent of its large teacher's accuracy using roughly 69 times fewer parameters. This study concludes that an effective teacher is not the largest one but a mid-capacity one, and that successful distillation also requires sufficient student capacity.

DAFTAR ISI

PERNYATAAN SIAP SEMINAR PROPOSAL SKRIPSI.....	ii
ABSTRAK.....	iii
ABSTRACT.....	iv
DAFTAR ISI.....	v
DAFTAR TABEL.....	viii
DAFTAR GAMBAR.....	ix
BAB 1.....	1
1.1 Latar Belakang.....	1
1.2 Batasan Masalah.....	3
1.3 Rumusan Masalah.....	3
1.4 Tujuan Penelitian.....	3
1.5 Manfaat Penelitian.....	4
1.5.1 Manfaat Praktis.....	4
1.5.2 Manfaat Teoritis.....	4
1.6 Kebaruan Penelitian.....	4
BAB 2.....	7
2.1 Tinjauan Pustaka.....	7
2.2 Landasan Teori.....	9
2.2.1 Klasifikasi Citra Sampah.....	9
2.2.2 Deep Learning.....	9
2.2.3 Convolutional Neural Network (CNN).....	10
2.2.4 Transfer Learning.....	11
2.2.5 Arsitektur Model.....	11
2.2.6 Knowledge Distillation.....	12
2.2.7 Teacher-Assistant Knowledge Distillation.....	14
2.2.8 Self-Distillation (Born-Again Networks).....	14
2.2.9 Preprocessing Citra.....	15
2.2.10 Data Augmentation.....	15
2.2.11 Dataset TrashNet.....	16
2.2.12 Evaluasi Model Klasifikasi.....	17
2.2.13 Uji Statistik.....	19
BAB 3.....	21

3.1	Pendekatan, Jenis, dan Prosedur Penelitian.....	21
3.1.1	Pendekatan Penelitian.....	21
3.1.2	Jenis Penelitian.....	21
3.1.3	Prosedur Penelitian.....	22
3.2	Lokasi dan Waktu Penelitian.....	23
3.3	Subjek Penelitian/Sampel dan Populasi.....	24
3.4	Data dan Sumber Data.....	24
3.5	Teknik Pengumpulan Data.....	24
3.6	Teknik Keabsahan Data.....	25
3.7	Teknik Analisis Data.....	25
3.7.1	Import Dataset.....	26
3.7.2	Preprocessing.....	26
3.7.3	Data Splitting.....	27
3.7.4	Data Augmentation.....	27
3.7.5	Arsitektur Model.....	28
3.7.6	<i>Knowledge Distillation</i>	28
3.7.7	Training Model.....	29
3.7.8	Model Evaluation.....	30
3.7.9	Uji Statistik.....	30
3.7.10	Skenario Pengujian.....	31
BAB 4		32
4.1	Hasil Penerapan Protokol Data.....	32
4.2	Kinerja Model Guru, Asisten, dan Baseline Student.....	32
4.3	Pengaruh Strategi Distilasi terhadap Kinerja Student.....	34
4.3.1	Distilasi Langsung dari Guru Besar.....	34
4.3.2	Distilasi melalui Teacher Assistant.....	35
4.3.3	Self-Distillation dengan Born-Again Networks.....	35
4.4	Hasil Uji Signifikansi Statistik.....	36
4.5	Analisis Kinerja per Kelas.....	37
4.6	Perbandingan Skema Lima Kelas dan Enam Kelas.....	39
4.7	Efisiensi Komputasi Model Student.....	39
4.8	Ablasi Komponen Arsitektur.....	40
4.9	Perbandingan dengan Penelitian Terdahulu.....	42

4.10	Pembahasan.....	44
BAB 5.....		46
5.1	Simpulan.....	46
5.2	Saran.....	47
DAFTAR PUSTAKA.....		48
LAMPIRAN.....		51

DAFTAR TABEL

Tabel 1.1 Kebaruan Penelitian.....	5
Tabel 2.1 Ringkasan Penelitian Terdahulu.....	8
Tabel 3.1 Confusion Matrix.....	30
Tabel 3.2 Skenario Pengujian Model.....	31
Tabel 4.1 Kinerja model guru, asisten, dan baseline student.....	33
Tabel 4.2 Pengaruh cara pelatihan asisten Focus-RCNet terhadap akurasinya.....	33
Tabel 4.3 Perbandingan akurasi seluruh skenario pelatihan student.....	34
Tabel 4.4 Hasil uji berpasangan setiap skema distilasi terhadap kontrolnya.....	36
Tabel 4.5 Selisih F1 per kelas pada skema TA-KD terhadap kontrolnya.....	37
Tabel 4.6 Selisih F1 per kelas pada skema self-distillation terhadap baseline.....	39
Tabel 4.7 Efisiensi komputasi model student pada resolusi masukan 160×160 piksel.....	39
Tabel 4.8 Hasil ablasi komponen arsitektur pada WasteNet-128K.....	40
Tabel 4.9 Hasil ablasi komponen arsitektur pada WasteNet-256K.....	41
Tabel 4.10 Perbandingan dengan penelitian terdahulu pada dataset TrashNet.....	42

DAFTAR GAMBAR

Gambar 2.1 Arsitektur Dasar Convolutional Neural Network.....	10
Gambar 2.2 Skema Knowledge Distillation.....	13
Gambar 2.3 Strategi Distilasi pada Kurva Capacity Gap.....	14
Gambar 2.4 Ilustrasi Teknik Data Augmentation.....	16
Gambar 2.5 Distribusi Jumlah Citra per Kelas pada Dataset TrashNet.....	17
Gambar 3.1 Diagram Alir Prosedur Penelitian.....	22
Gambar 3.2 Diagram Alir Teknik Analisis Data.....	26
Gambar 3.3 Arsitektur Model Guru, Asisten, dan Student.....	28
Gambar 4.1 Distribusi Jumlah Citra per Kelas dan per Subset Data.....	32
Gambar 4.2 Akurasi Student pada Seluruh Skenario Pelatihan beserta Simpangan Bakunya.....	34
Gambar 4.3 Kurva Loss dan Akurasi Pelatihan Skema TA-KD pada WasteNet-256K.....	35
Gambar 4.4 Perbandingan Selisih F1 per Kelas pada Skema TA-KD antara Skema K6 dan K5.....	38
Gambar 4.5 Confusion Matrix Data Uji (kiri: kontrol cross-entropy, kanan: TA-KD).....	38
Gambar 4.6 Hasil Ablasi Komponen Arsitektur pada Kedua Varian WasteNet.....	42
Gambar 4.7 Perubahan Akurasi Student menurut Kapasitas Guru.....	44

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Pengelolaan sampah merupakan salah satu permasalahan lingkungan yang paling mendesak, baik di Indonesia maupun di tingkat global. Laporan *What a Waste 2.0* memperkirakan timbunan sampah kota (*municipal solid waste*) dunia mencapai sekitar 2,01 miliar ton pada tahun 2016 dan diproyeksikan meningkat menjadi 3,40 miliar ton pada tahun 2050, sementara baru sekitar 13,5% yang didaur ulang (Kaza dkk., 2018). Di Indonesia, berdasarkan data Sistem Informasi Pengelolaan Sampah Nasional (SIPSN), timbunan sampah nasional mencapai lebih dari 50 juta ton per tahun dengan tingkat penanganan dan daur ulang yang masih terbatas (Kementerian Lingkungan Hidup dan Kehutanan, 2023). Volume timbunan sampah terus meningkat seiring pertumbuhan penduduk, urbanisasi, dan perubahan pola konsumsi masyarakat, sementara kapasitas pengolahan dan tingkat daur ulang masih relatif rendah. Salah satu tahap kunci dalam upaya daur ulang adalah pemilahan sampah berdasarkan jenis materialnya, seperti kertas, plastik, logam, dan kaca. Ketepatan pemilahan menentukan efektivitas proses daur ulang selanjutnya, namun hingga saat ini sebagian besar pemilahan masih dilakukan secara manual.

Pemilahan sampah secara manual memiliki sejumlah keterbatasan, antara lain membutuhkan tenaga kerja yang besar, rentan terhadap kesalahan, serta kurang konsisten dan tidak efisien untuk volume sampah yang besar. Oleh karena itu, dibutuhkan sistem pemilahan otomatis yang mampu mengenali jenis sampah secara cepat dan akurat. Perkembangan teknologi *computer vision* dan *deep learning* membuka peluang untuk membangun sistem klasifikasi citra sampah otomatis yang dapat menjadi dasar bagi tempat sampah pintar (*smart bin*) maupun lini pemilahan otomatis pada fasilitas pengolahan sampah.

Salah satu pendekatan yang banyak digunakan dalam klasifikasi citra adalah *Convolutional Neural Network* (CNN), yang terbukti mampu mengekstraksi fitur visual secara hierarkis dan mencapai akurasi tinggi pada berbagai tugas pengenalan citra. Dalam domain klasifikasi sampah, *dataset* TrashNet yang diperkenalkan oleh Thung dan Yang (2016) menjadi salah satu tolok ukur yang umum digunakan. *Dataset* ini memuat citra sampah yang dikelompokkan ke dalam enam kelas, yaitu *cardboard*, *glass*, *metal*, *paper*, *plastic*, dan *trash*, sehingga banyak dimanfaatkan untuk menguji berbagai arsitektur klasifikasi citra sampah.

Meskipun arsitektur CNN modern mampu mencapai akurasi yang tinggi, model-model tersebut umumnya memiliki jumlah parameter yang sangat besar dan kebutuhan komputasi yang berat. Hal ini menjadi kendala ketika model akan diterapkan pada perangkat dengan sumber daya terbatas, seperti perangkat *embedded*, *mobile*, maupun *edge device* yang menjadi target penerapan tempat sampah pintar. Terdapat *trade-off* antara akurasi dan ukuran model, sehingga diperlukan model yang ringan namun tetap memiliki performa yang memadai.

Untuk menjawab kebutuhan tersebut, berbagai teknik kompresi model dikembangkan, salah satunya adalah *knowledge distillation* (KD). *Knowledge distillation* yang diperkenalkan oleh Hinton dkk. (2015) merupakan teknik mentransfer pengetahuan dari sebuah model besar (*teacher*) kepada model yang lebih kecil (*student*) melalui *soft target*, yaitu distribusi probabilitas keluaran *teacher* yang mengandung informasi tambahan atau *dark knowledge*. Dengan demikian, *student* dapat mencapai performa yang lebih baik dibandingkan jika dilatih langsung hanya dari label keras (*hard label*), sambil tetap mempertahankan ukuran yang ringan.

Namun, efektivitas *knowledge distillation* tidak selalu terjamin. Cho dan Hariharan (2019) menunjukkan bahwa ketika selisih kapasitas antara *teacher* dan *student* terlalu besar (*capacity gap*), proses distilasi justru dapat menurunkan performa *student*. Untuk mengatasi hal tersebut, Mirzadeh dkk. (2020) mengusulkan skema *teacher-assistant knowledge distillation* (TA-KD), yaitu menyisipkan model perantara berkapasitas menengah (*teacher assistant*) sebagai jembatan antara *teacher* besar dan *student* kecil, sehingga pengetahuan dapat ditransfer secara lebih bertahap.

Selain skema *teacher-assistant*, terdapat pula pendekatan *self-distillation*, di antaranya *Born-Again Networks* (BAN) yang diperkenalkan oleh Furlanello dkk. (2018), yaitu *student* dilatih dengan *teacher* yang memiliki arsitektur dan kapasitas yang sama dengan dirinya dari generasi sebelumnya. Dengan adanya tiga jenis *teacher* tersebut, yaitu *teacher* besar, *teacher* berkapasitas menengah (*assistant*), dan *teacher* berkapasitas sama (*self*), muncul pertanyaan jenis *teacher* manakah yang paling efektif untuk membantu *student* yang berukuran sangat ringan.

Salah satu penelitian terkini yang menjadi acuan utama penelitian ini adalah Focus-RCNet (Zheng dkk., 2023), yaitu model klasifikasi sampah daur ulang yang ringan dengan *knowledge distillation* dari *teacher* EfficientNet-B4 pada *dataset* TrashNet dan mencapai akurasi sekitar 92%. Meskipun demikian, sebagian besar penelitian terdahulu yang menggunakan *dataset* TrashNet, termasuk Focus-RCNet, masih berfokus pada peningkatan akurasi tanpa membandingkan secara sistematis pengaruh kapasitas *teacher* terhadap *student* yang sangat ringan. Selain itu, pengaruh *capacity gap* dalam *knowledge distillation* umumnya diuji pada *dataset* berskala besar seperti CIFAR maupun ImageNet, dan belum banyak diteliti pada model ultra-ringan untuk klasifikasi sampah. Hal inilah yang menjadi celah yang melatarbelakangi penelitian ini.

Berdasarkan uraian tersebut, penelitian ini mengembangkan model ringan WasteNet (dengan kisaran 128 ribu hingga 256 ribu parameter) untuk klasifikasi citra sampah TrashNet melalui *knowledge distillation*, serta membandingkan tiga jenis *teacher* berdasarkan kapasitasnya, yaitu *large-teacher* (EfficientNet-B4), *assistant* (Focus-RCNet; Zheng dkk., 2023), dan *self-distillation* (*Born-Again Networks*). Penelitian ini juga menerapkan pengujian statistik untuk memvalidasi perbedaan performa terhadap *baseline* tanpa distilasi, dan dilakukan pada dua ruang

label, yaitu enam kelas penuh dan varian lima kelas, guna menguji konsistensi temuan.

1.2 Batasan Masalah

Agar penelitian ini terarah dan terukur, penulis menetapkan batasan masalah sebagai berikut:

1. *Dataset* yang digunakan adalah TrashNet (Thung & Yang, 2016) berupa citra sampah, dengan dua ruang label yang diuji, yaitu enam kelas penuh (*cardboard, glass, metal, paper, plastic, trash*) dan varian lima kelas tanpa kelas *trash*.
2. Arsitektur model dibatasi pada *student* ringan WasteNet (sekitar 128 ribu dan 256 ribu parameter), *teacher assistant* Focus-RCNet (Zheng dkk., 2023; sekitar 520 ribu parameter), dan *teacher* besar EfficientNet-B4.
3. Metode distilasi dibatasi pada *response-based knowledge distillation* (berbasis *soft target*) dengan tiga jenis *teacher*, yaitu *large-teacher*, *teacher-assistant*, dan *self-distillation* (Born-Again Networks).
4. Evaluasi performa model menggunakan metrik klasifikasi seperti *accuracy, precision, recall*, dan *F1-score*, serta uji statistik berupa *paired t-test*, uji Wilcoxon, dan uji McNemar.
5. Seluruh eksperimen dijalankan menggunakan Kaggle sebagai *workspace*.

1.3 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membangun model ringan WasteNet untuk klasifikasi citra sampah TrashNet menggunakan *knowledge distillation*?
2. Bagaimana pengaruh kapasitas *teacher*, yaitu *large-teacher* (EfficientNet-B4), *assistant* (Focus-RCNet), dan *self-distillation* (Born-Again Networks), terhadap performa *student* WasteNet, dan jenis *teacher* manakah yang paling efektif?
3. Bagaimana performa model yang dihasilkan jika dievaluasi secara statistik dibandingkan dengan *baseline* tanpa *knowledge distillation*?

1.4 Tujuan Penelitian

Sejalan dengan rumusan masalah tersebut, penelitian ini memiliki tujuan sebagai berikut:

1. Membangun model ringan WasteNet untuk klasifikasi citra sampah TrashNet menggunakan *knowledge distillation*.
2. Menganalisis pengaruh kapasitas *teacher* (*large-teacher, assistant, dan self-distillation*) terhadap performa *student* WasteNet serta menentukan jenis *teacher* yang paling efektif untuk *student* berkapasitas kecil.
3. Mengevaluasi performa model yang dihasilkan secara statistik dibandingkan dengan *baseline* tanpa *knowledge distillation*.

1.5 Manfaat Penelitian

1.5.1 Manfaat Praktis

1. Menghasilkan model klasifikasi citra sampah yang ringan dan efisien sehingga berpotensi diterapkan pada perangkat dengan sumber daya terbatas, seperti *smart bin* maupun perangkat *embedded*, untuk mendukung pemilahan sampah otomatis.
2. Memberikan rekomendasi pemilihan strategi *knowledge distillation* yang sesuai dalam pengembangan model ringan untuk tugas klasifikasi citra.

1.5.2 Manfaat Teoritis

1. Memberikan kontribusi keilmuan mengenai pengaruh *capacity gap* antara *teacher* dan *student* dalam *knowledge distillation*, khususnya pada skema *teacher-assistant*.
2. Menambah referensi akademik mengenai perbandingan *large-teacher*, *teacher-assistant*, dan *self-distillation* pada pengembangan model ringan untuk klasifikasi citra sampah.

1.6 Kebaruan Penelitian

Penelitian ini secara khusus dikembangkan dari Focus-RCNet (Zheng dkk., 2023), sebuah model klasifikasi sampah daur ulang yang ringan dengan *knowledge distillation* pada *dataset* TrashNet. Selain itu, penelitian ini juga berakar pada rangkaian studi mengenai *knowledge distillation*, mulai dari konsep awal oleh Hinton dkk. (2015), temuan Cho dan Hariharan (2019) mengenai *capacity gap*, skema *teacher-assistant* oleh Mirzadeh dkk. (2020), hingga *self-distillation* melalui *Born-Again Networks* oleh Furlanello dkk. (2018). Sebagian besar studi *capacity gap* tersebut diuji pada *dataset* berskala besar seperti CIFAR dan ImageNet dengan *student* berukuran sedang. Kebaruan penelitian ini terletak pada penggunaan ulang Focus-RCNet sebagai *teacher-assistant* sekaligus perbandingan terkontrol ketiga jenis *teacher* pada *student* ultra-ringan WasteNet untuk klasifikasi citra sampah TrashNet, yang masih jarang dikaji.

Penelitian yang paling berkaitan dengan penelitian ini adalah Focus-RCNet yang dikembangkan oleh Zheng dkk. (2023), yaitu algoritma klasifikasi sampah daur ulang yang ringan berbasis modul *Focus* dan *knowledge distillation*. Model tersebut diuji pada *dataset* TrashNet dengan enam kelas dan mencapai akurasi sekitar 92% setelah proses distilasi menggunakan EfficientNet-B4 sebagai *teacher*. Meskipun sudah tergolong ringan, Focus-RCNet masih memiliki jumlah parameter yang jauh lebih besar dibandingkan *student* yang ditargetkan pada penelitian ini, dan belum membandingkan pengaruh kapasitas *teacher* yang berbeda terhadap performa *student*.

Penelitian yang dilakukan oleh Hinton dkk. (2015) memperkenalkan konsep *knowledge distillation*, yaitu mentransfer pengetahuan dari *teacher* besar ke *student* kecil melalui *soft target* dengan parameter suhu (*temperature*). Pendekatan ini

berhasil meningkatkan performa *student*, namun belum secara khusus membahas kondisi ketika selisih kapasitas antara *teacher* dan *student* sangat besar.

Cho dan Hariharan (2019) menelaah keterbatasan *knowledge distillation* dan menemukan bahwa *teacher* yang terlalu besar tidak selalu menghasilkan *student* yang lebih baik akibat adanya *capacity gap*. Mereka menyarankan penghentian pelatihan *teacher* lebih awal (*early stopping*) untuk memperkecil selisih kapasitas, namun pengujian dilakukan pada *dataset* citra umum, bukan pada tugas klasifikasi sampah dengan *student* ultra-ringan.

Mirzadeh dkk. (2020) mengusulkan *teacher-assistant knowledge distillation* (TA-KD) dengan menyisipkan model perantara berkapasitas menengah untuk menjembatani *teacher* besar dan *student* kecil. Skema ini terbukti efektif pada *dataset* CIFAR dan ImageNet, tetapi belum diterapkan secara luas pada model dengan parameter sangat kecil untuk klasifikasi citra sampah.

Furlanello dkk. (2018) memperkenalkan *Born-Again Networks* (BAN), yaitu skema *self-distillation* dengan *teacher* berkapasitas sama dengan *student* dari generasi sebelumnya, yang mampu meningkatkan performa sekaligus berperan sebagai regularisasi. Namun, efektivitas BAN pada *student* yang sangat ringan dan pada *dataset* berskala kecil seperti TrashNet masih belum banyak dieksplorasi.

Ringkasan penelitian-penelitian terdahulu yang telah diuraikan di atas disajikan pada Tabel 1.1 berikut.

Tabel 1.1 Kebaruan Penelitian

Peneliti	Metode	Dataset	Fokus Utama	Kelemahan
Zheng dkk. (2023)	Focus-RCNet (<i>Focus + knowledge distillation</i>)	TrashNet (6 kelas)	Klasifikasi sampah ringan, KD dari EfficientNet-B4 (akurasi ~92%)	Parameter masih relatif besar; belum membandingkan kapasitas <i>teacher</i>
Hinton dkk. (2015)	<i>Knowledge distillation (soft target)</i>	MNIST, <i>speech recognition</i>	Transfer <i>dark knowledge</i> dari <i>teacher</i> ke <i>student</i>	Belum membahas <i>capacity gap</i> pada <i>student</i> yang sangat kecil
Cho & Hariharan (2019)	<i>Early-stopped KD</i>	CIFAR-10, ImageNet	Mengatasi <i>capacity gap</i> dengan <i>early stopping</i>	Tidak diuji pada model ultra-ringan untuk klasifikasi sampah
Mirzadeh dkk.	<i>Teacher-</i>	CIFAR-10	Menjembata	Belum diterapkan

(2020)	<i>assistant</i> KD (TA- KD)	/100, ImageNet	ni <i>teacher</i> besar dan <i>student</i> kecil	pada <i>student</i> berparameter sangat kecil untuk citra sampah
Furlanello dkk. (2018)	<i>Born-Again</i> <i>Networks</i> (<i>self-</i> <i>distillation</i>)	CIFAR-10 /100, <i>Penn</i> <i>Treebank</i>	<i>Self-</i> <i>distillation</i> berkapasitas sama dan regularisasi	Belum dieksplorasi pada <i>student</i> ringan dan <i>dataset</i> kecil seperti TrashNet

Berangkat dari telaah penelitian sebelumnya, khususnya Focus-RCNet (Zheng dkk., 2023), penelitian ini mengusulkan klasifikasi citra sampah TrashNet menggunakan model ringan WasteNet melalui *knowledge distillation* dengan membandingkan tiga jenis *teacher* berdasarkan kapasitasnya, yaitu *large-teacher* (EfficientNet-B4), *teacher-assistant* (Focus-RCNet), dan *self-distillation* (*Born-Again Networks*), serta memvalidasi hasilnya menggunakan uji statistik pada dua ruang label (lima dan enam kelas). Pendekatan inilah yang membedakan penelitian ini dari studi-studi sebelumnya.

BAB 2 KAJIAN PUSTAKA

2.1 Tinjauan Pustaka

Penelitian ini dikembangkan dari sejumlah penelitian terdahulu yang memiliki keterkaitan dengan metode, dataset, serta objek penelitian yang digunakan. Penelusuran literatur bertujuan untuk memahami posisi penelitian terhadap karya-karya sebelumnya sekaligus menetapkan batasan dan arah pengembangan yang dilakukan. Beberapa penelitian yang relevan dengan klasifikasi citra sampah dan *knowledge distillation* diuraikan sebagai berikut.

Penelitian yang dilakukan oleh Thung dan Yang (2016) memperkenalkan dataset TrashNet sebagai tolok ukur untuk klasifikasi citra sampah yang dapat didaur ulang. Dataset tersebut terdiri atas 2.527 citra yang dikelompokkan ke dalam enam kelas, yaitu *cardboard*, *glass*, *metal*, *paper*, *plastic*, dan *trash*. Pada penelitian tersebut, Thung dan Yang membandingkan metode *Support Vector Machine* (SVM) dengan fitur SIFT dan *Convolutional Neural Network* (CNN), dan memperoleh akurasi terbaik sekitar 63% menggunakan SVM, sedangkan CNN belum optimal akibat keterbatasan data. Penelitian ini menjadi dasar bagi banyak studi klasifikasi sampah berikutnya, termasuk penelitian yang diusulkan, yang menggunakan dataset TrashNet sebagai data utama.

Penelitian yang dilakukan oleh Zheng dkk. (2023) mengusulkan Focus-RCNet, yaitu model ringan untuk klasifikasi sampah daur ulang yang memadukan modul *Focus* dan *knowledge distillation*. Modul *Focus* digunakan untuk mereduksi dimensi spasial citra tanpa kehilangan informasi penting, sedangkan mekanisme atensi *SimAM* tanpa parameter ditambahkan untuk memperkuat representasi fitur. Model Focus-RCNet kemudian disempurnakan melalui *knowledge distillation* dengan guru EfficientNet-B4 untuk lebih memampatkan ukuran model; secara keseluruhan Focus-RCNet mencapai akurasi terbaik sekitar 92,2% pada dataset TrashNet. Penelitian tersebut menjadi rujukan utama penelitian ini, yang mereimplementasikan Focus-RCNet sebagai model asisten (*teacher assistant*) sekaligus memanfaatkan EfficientNet-B4 sebagai guru besar.

Penelitian yang dilakukan oleh Hinton dkk. (2015) memperkenalkan konsep *knowledge distillation* sebagai teknik kompresi model dengan cara melatih model *student* berukuran kecil untuk menirukan distribusi probabilitas keluaran (*soft label*) model guru yang lebih besar. Distribusi *soft label* yang dihaluskan menggunakan parameter suhu (*temperature*) membawa *dark knowledge*, yaitu informasi kemiripan antarkelas yang tidak terdapat pada label keras. Hinton dkk. menunjukkan bahwa *student* yang dilatih dengan *soft label* dapat memperoleh performa yang mendekati guru meskipun memiliki kapasitas yang jauh lebih kecil. Konsep ini menjadi landasan teoretis bagi seluruh strategi distilasi yang dibandingkan pada penelitian ini.

Penelitian yang dilakukan oleh Cho dan Hariharan (2019) mengkaji efektivitas *knowledge distillation* secara empiris dan menemukan bahwa guru berkapasitas sangat besar tidak selalu menghasilkan *student* yang lebih baik. Mereka mengidentifikasi adanya *capacity gap*, yaitu selisih kapasitas yang terlalu besar antara guru dan *student* yang justru menghambat transfer pengetahuan. Sebagai solusi, Cho dan Hariharan menyarankan penghentian dini pelatihan guru atau penggunaan guru dengan kapasitas yang lebih sepadan. Temuan ini menjadi motivasi utama penelitian ini dalam membandingkan beberapa jenis guru pada kurva *capacity gap*.

Penelitian yang dilakukan oleh Mirzadeh dkk. (2020) mengusulkan *teacher-assistant knowledge distillation* (TA-KD) untuk mengatasi permasalahan *capacity gap*. Pendekatan ini menyisipkan satu model perantara berkapasitas menengah (*teacher assistant*) yang menjembatani selisih kapasitas antara guru besar dan *student*. Hasil eksperimen pada beberapa dataset menunjukkan bahwa distilasi bertahap melalui asisten menghasilkan *student* yang lebih akurat dibandingkan distilasi langsung dari guru besar. Pendekatan TA-KD ini menjadi metode inti pada penelitian yang diusulkan, dengan Focus-RCNet berperan sebagai asisten.

Penelitian yang dilakukan oleh Furlanello dkk. (2018) memperkenalkan *Born-Again Networks* (BAN), yaitu bentuk *self-distillation* yang menggunakan guru dengan arsitektur dan kapasitas yang sama dengan *student*. Pada pendekatan ini, model dilatih secara berurutan antargenerasi, dengan model generasi sebelumnya bertindak sebagai guru bagi generasi berikutnya. Furlanello dkk. menunjukkan bahwa *student* hasil distilasi dapat menyamai bahkan melampaui performa gurunya meskipun memiliki kapasitas yang identik. Pendekatan BAN ini digunakan pada penelitian ini sebagai titik ujung kurva *capacity gap*, yaitu kondisi saat kapasitas guru sama dengan *student*. Ringkasan penelitian terdahulu disajikan pada Tabel 2.1.

Tabel 2.2 Ringkasan Penelitian Terdahulu

No	Penulis (Tahun)	Metode/Dataset	Fokus Utama
1	Thung & Yang (2016)	SVM, CNN / TrashNet	Memperkenalkan dataset TrashNet sebagai tolok ukur klasifikasi sampah
2	Zheng dkk. (2023)	Focus-RCNet + KD / TrashNet	Model ringan dengan modul Focus, SimAM, dan distilasi (akurasi $\pm 92,2\%$)
3	Hinton dkk. (2015)	Knowledge Distillation	Memperkenalkan distilasi pengetahuan melalui soft label dan temperature
4	Cho & Hariharan (2019)	Analisis KD	Mengidentifikasi capacity gap antara guru dan student
5	Mirzadeh dkk. (2020)	TA-KD	Menyisipkan asisten menengah untuk menjembatani capacity gap
6	Furlanello dkk. (2018)	Born-Again Networks	Self-distillation dengan guru berkapasitas sama

Berdasarkan penelitian-penelitian tersebut, terlihat bahwa *knowledge distillation* telah terbukti efektif untuk mengompresi model, namun pengaruh jenis dan kapasitas guru terhadap keberhasilan distilasi pada model sangat ringan untuk klasifikasi citra sampah belum dikaji secara menyeluruh dalam satu kerangka eksperimen. Penelitian ini mengisi celah tersebut dengan membandingkan tiga jenis guru, yaitu guru besar, asisten menengah, dan guru berkapasitas sama, di sepanjang kurva *capacity gap* pada model ringan WasteNet.

2.2 Landasan Teori

2.2.1 Klasifikasi Citra Sampah

Klasifikasi citra sampah merupakan proses pengelompokan citra sampah ke dalam kategori jenis material tertentu secara otomatis menggunakan model komputasi. Pemilahan sampah berdasarkan jenis materialnya merupakan langkah penting dalam proses daur ulang, karena material yang tercampur dapat menurunkan kualitas hasil daur ulang dan menyulitkan proses pengolahan (Thung & Yang, 2016). Secara konvensional, pemilahan sampah dilakukan secara manual oleh manusia, yang membutuhkan waktu, tenaga, serta berisiko terhadap kesehatan pekerja. Oleh karena itu, sistem klasifikasi citra sampah otomatis berbasis visi komputer menjadi solusi yang menjanjikan untuk meningkatkan efisiensi dan akurasi pemilahan sampah.

Dalam beberapa tahun terakhir, pendekatan berbasis *deep learning* menjadi metode dominan dalam klasifikasi citra sampah karena kemampuannya mempelajari fitur visual secara otomatis dari data citra (Zheng dkk., 2023). Model klasifikasi dilatih untuk mengenali pola visual yang membedakan jenis material, seperti tekstur kertas, transparansi kaca, atau kilau logam. Meskipun demikian, penerapan model *deep learning* pada perangkat dengan keterbatasan komputasi, seperti perangkat tepi (*edge device*), masih menghadapi tantangan akibat besarnya ukuran dan kebutuhan komputasi model. Hal inilah yang mendorong pengembangan model ringan yang tetap akurat melalui teknik kompresi seperti *knowledge distillation*.

2.2.2 Deep Learning


Deep learning merupakan cabang pembelajaran mesin yang menggunakan jaringan saraf tiruan dengan banyak lapisan tersembunyi untuk mempelajari representasi data secara hierarkis (LeCun dkk., 2015). Arsitektur *deep learning* tersusun atas lapisan masukan, beberapa lapisan tersembunyi, dan lapisan keluaran yang saling terhubung melalui bobot dan fungsi aktivasi nonlinier (Goodfellow dkk., 2016). Penambahan lapisan tersembunyi memungkinkan model mengekstraksi fitur dari tingkat rendah hingga tingkat abstrak secara bertahap dari data masukan (Schmidhuber, 2015). Struktur berlapis inilah yang membedakan *deep learning* dari jaringan saraf dangkal serta menjadikannya unggul dalam menangani data berdimensi tinggi seperti citra.

Pada tahap pelatihan, *deep learning* memperbarui bobot jaringan melalui mekanisme propagasi balik (*backpropagation*) dengan meminimalkan fungsi kerugian (*loss function*) yang mengukur kesalahan prediksi model (Goodfellow dkk., 2016). Keberhasilan *deep learning* dalam tugas pengenalan citra berskala besar mulai menonjol sejak diperkenalkannya arsitektur AlexNet pada kompetisi ImageNet (Krizhevsky dkk., 2012). Sejak saat itu, berbagai arsitektur *deep learning*, khususnya *Convolutional Neural Network*, berkembang pesat dan menjadi standar dalam tugas klasifikasi citra. Kemampuan mempelajari fitur secara otomatis tanpa rekayasa fitur manual menjadikan *deep learning* sangat relevan untuk klasifikasi citra sampah.

2.2.3 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan arsitektur *deep learning* yang dirancang khusus untuk memproses data citra dengan memanfaatkan struktur spasialnya (O'Shea & Nash, 2015). CNN bekerja dengan menerapkan operasi konvolusi menggunakan kernel pada citra masukan untuk mengekstraksi fitur lokal, seperti tepi dan pola sederhana (LeCun dkk., 1998). Proses konvolusi memungkinkan jaringan mempelajari representasi fitur secara bertahap dari tingkat rendah hingga tingkat yang lebih abstrak (Goodfellow dkk., 2016). Pendekatan ini menjadikan CNN lebih efisien dibandingkan jaringan saraf *fully connected* dalam menangani data citra berdimensi tinggi (Krizhevsky dkk., 2012).

Arsitektur CNN umumnya tersusun atas beberapa lapisan utama, yaitu *convolutional layer*, fungsi aktivasi, *pooling layer*, dan *fully connected layer*, sebagaimana ditunjukkan pada Gambar 2.1.



Gambar 2.1 Arsitektur Dasar Convolutional Neural Network

Convolutional layer berfungsi mengekstraksi fitur spasial dari citra masukan melalui operasi konvolusi dengan ukuran kernel tertentu (LeCun dkk., 1998). Fungsi aktivasi, seperti *Rectified Linear Unit* (ReLU), digunakan untuk memperkenalkan nonlinieritas sehingga jaringan mampu mempelajari pola yang lebih kompleks (Nair & Hinton, 2010). *Pooling layer*, seperti *max pooling*, mereduksi dimensi *feature map* sekaligus mempertahankan informasi penting, sehingga meningkatkan efisiensi komputasi dan ketahanan terhadap variasi posisi objek (Goodfellow dkk., 2016). Setelah ekstraksi fitur, *fully connected layer*

menggabungkan fitur yang telah dipelajari untuk menghasilkan keluaran berupa prediksi kelas (O'Shea & Nash, 2015).

2.2.4 Transfer Learning

Transfer learning merupakan pendekatan pembelajaran mesin yang memanfaatkan pengetahuan dari model yang telah dilatih pada dataset berskala besar untuk diterapkan pada tugas atau domain yang berbeda namun masih berkaitan (Pan & Yang, 2010). Pendekatan ini banyak digunakan pada *deep learning* karena pelatihan jaringan dari awal membutuhkan data dalam jumlah besar serta sumber daya komputasi yang tinggi (Goodfellow dkk., 2016). Dengan memanfaatkan model pralatih (*pretrained model*), proses pelatihan dapat dipercepat dan performa model dapat ditingkatkan, khususnya ketika data pelatihan terbatas. Oleh karena itu, *transfer learning* menjadi strategi yang umum diterapkan dalam berbagai aplikasi visi komputer modern.

Dalam visi komputer, *transfer learning* umumnya diterapkan menggunakan model pralatih yang dilatih pada dataset ImageNet yang terdiri atas lebih dari satu juta citra dengan ribuan kelas objek (Russakovsky dkk., 2015). Lapisan awal model pralatih telah mempelajari representasi fitur umum, seperti tepi, sudut, dan tekstur, yang dapat ditransfer ke berbagai tugas klasifikasi citra lainnya. Pada penelitian ini, model guru EfficientNet-B4 memanfaatkan bobot pralatih ImageNet agar mampu menghasilkan representasi fitur yang kaya meskipun jumlah data TrashNet relatif terbatas (Tan & Le, 2019). Pengetahuan dari guru pralatih inilah yang kemudian ditransfer ke model *student* ringan melalui mekanisme *knowledge distillation*.

2.2.5 Arsitektur Model

Penelitian ini melibatkan tiga peran model dengan kapasitas yang berbeda dalam skema *knowledge distillation*, yaitu guru besar, asisten menengah, dan *student* ringan. Ketiga model tersebut digunakan untuk menguji pengaruh kapasitas guru terhadap keberhasilan transfer pengetahuan ke model *student*. Penjelasan masing-masing arsitektur diuraikan sebagai berikut.

Model guru besar yang digunakan adalah EfficientNet-B4, yaitu arsitektur CNN yang dikembangkan dengan pendekatan *compound scaling* yang menyeimbangkan kedalaman, lebar, dan resolusi jaringan secara proporsional (Tan & Le, 2019). EfficientNet-B4 memiliki sekitar 17,6 juta parameter dan dilatih menggunakan bobot pralatih ImageNet, sehingga mampu menghasilkan representasi fitur dengan performa tertinggi sekaligus menjadi batas atas kinerja pada penelitian ini. Kapasitasnya yang besar menjadikannya sumber pengetahuan pada skema distilasi langsung dari guru besar, sekaligus menjadi titik berkapasitas terbesar pada kurva capacity gap yang dibandingkan dalam penelitian ini.

Model asisten yang digunakan adalah Focus-RCNet, yaitu model ringan berkapasitas menengah dengan sekitar 520 ribu parameter yang

direimplementasikan dari penelitian Zheng dkk. (2023). Focus-RCNet memadukan modul *Focus* untuk mereduksi dimensi spasial citra secara efisien dengan mekanisme atensi *SimAM* tanpa parameter untuk memperkuat representasi fitur. Dalam penelitian ini, Focus-RCNet berperan sebagai guru perantara (*teacher assistant*) yang menjembatani selisih kapasitas antara guru besar dan *student* ringan, sesuai dengan pendekatan TA-KD.


Model *student* yang menjadi sasaran akhir penelitian ini adalah WasteNet, yaitu model CNN ringan yang dirancang khusus untuk klasifikasi citra sampah pada perangkat dengan keterbatasan komputasi. WasteNet diimplementasikan dalam dua varian kapasitas, yaitu WasteNet-128K dengan sekitar 128 ribu parameter dan WasteNet-256K dengan sekitar 256 ribu parameter, untuk menganalisis pengaruh kapasitas *student* terhadap efektivitas distilasi. Ukurannya yang sangat kecil menjadikan WasteNet efisien untuk diterapkan secara nyata, namun sekaligus menuntut strategi pelatihan yang tepat agar tetap memperoleh akurasi yang memadai.

Secara arsitektural, WasteNet disusun dari blok konvolusi *depthwise-separable* dengan struktur *inverted residual* yang mengadopsi prinsip efisiensi keluarga MobileNet (Howard dkk., 2017; Sandler dkk., 2018) dan EfficientNet (Tan & Le, 2019), bukan diturunkan dari model bernama sama WasteNet (White dkk., 2020) yang berbasis DenseNet. Jaringan diawali sebuah lapisan konvolusi standar berukuran 3×3 dengan stride 2 (*convolution-batch normalization-SiLU*) yang menurunkan resolusi spasial, kemudian diikuti beberapa tahap blok *depthwise-separable*. Setiap blok memperluas kanal melalui konvolusi *pointwise* 1×1 , menerapkan konvolusi *depthwise* 3×3 , lalu memproyeksikan kembali kanal melalui konvolusi 1×1 , disertai *batch normalization* dan aktivasi SiLU pada tiap tahap serta koneksi *residual* ketika dimensi masukan dan keluaran sama. Seluruh operasi spasial pada WasteNet menggunakan kernel berukuran 3×3 , sedangkan kernel 1×1 digunakan untuk mencampur informasi antar-kanal, tanpa penggunaan kernel yang lebih besar demi menekan jumlah parameter. Bagian akhir jaringan berupa *global average pooling* yang diikuti satu lapisan *fully-connected* sebagai pengklasifikasi. Jumlah kanal dan pengulangan blok diatur sedemikian rupa sehingga total parameter berada pada kisaran sekitar 128 ribu (WasteNet-128K) dan 256 ribu (WasteNet-256K); ukuran ini sengaja dibuat sangat kecil agar tersedia ruang kapasitas yang memadai untuk mengamati pengaruh *knowledge distillation*. Dengan demikian, WasteNet merupakan arsitektur *student* yang dikembangkan dalam penelitian ini, dan kesamaan namanya dengan WasteNet (White dkk., 2020) yang berbasis DenseNet bersifat kebetulan.

2.2.6 Knowledge Distillation

Knowledge distillation merupakan teknik kompresi model yang melatih model *student* berukuran kecil untuk menirukan keluaran model guru yang lebih besar (Hinton dkk., 2015). Selain mempelajari label sebenarnya melalui *hard label*,

student juga mempelajari distribusi probabilitas keluaran guru (*soft label*) yang dihaluskan menggunakan parameter suhu (*temperature*). Distribusi *soft label* tersebut membawa *dark knowledge*, yaitu informasi kemiripan antarkelas yang tidak terdapat pada *hard label*. Skema umum proses *knowledge distillation* dari guru ke *student* ditunjukkan pada Gambar 2.2.



Gambar 2.2 Skema Knowledge Distillation

Distribusi *soft label* diperoleh dengan menghaluskan keluaran lapisan akhir (*logit*) menggunakan fungsi *softmax* yang dimodifikasi dengan parameter suhu T , sebagaimana dirumuskan pada Persamaan (2.1). Semakin besar nilai T , semakin halus distribusi probabilitas yang dihasilkan, sehingga informasi kemiripan antarkelas menjadi lebih menonjol (Hinton dkk., 2015).

$$q_i = \frac{\exp\left(\frac{z_i}{T}\right)}{\sum_j \exp\left(\frac{z_j}{T}\right)} \quad (2.1)$$

dengan q_i merupakan probabilitas kelas ke- i hasil pelunakan, z_i dan z_j adalah nilai *logit* untuk kelas ke- i dan ke- j , serta T adalah parameter suhu (*temperature*) yang mengontrol tingkat pelunakan distribusi (Hinton dkk., 2015).

Fungsi kerugian total pada *knowledge distillation* merupakan kombinasi berbobot antara *cross-entropy* terhadap label sebenarnya dan divergensi Kullback-Leibler terhadap *soft label* guru, dengan koefisien pembobotan alfa, sebagaimana ditunjukkan pada Persamaan (2.2).

$$L_{KD} = (1 - \alpha) L_{CE} + \alpha T^2 D_{KL}(p_t \parallel p_s) \quad (2.2)$$

dengan L_{KD} merupakan fungsi kerugian total *knowledge distillation*, L_{CE} adalah fungsi *cross-entropy* terhadap label sebenarnya, D_{KL} adalah divergensi Kullback-Leibler terhadap *soft label* guru, α adalah koefisien pembobotan ($0 \leq \alpha \leq 1$), T


adalah parameter suhu, serta p_t dan p_s merupakan distribusi probabilitas keluaran guru dan *student* (Hinton dkk., 2015).

2.2.7 Teacher-Assistant Knowledge Distillation


Teacher-assistant knowledge distillation (TA-KD) merupakan pengembangan dari *knowledge distillation* yang dirancang untuk mengatasi permasalahan *capacity gap* antara guru dan *student* (Mirzadeh dkk., 2020). *Capacity gap* terjadi ketika selisih kapasitas antara guru besar dan *student* terlalu jauh, sehingga *student* kesulitan menirukan keluaran guru dan transfer pengetahuan menjadi tidak optimal (Cho & Hariharan, 2019). Untuk mengatasinya, TA-KD menyisipkan satu atau lebih model perantara berkapasitas menengah yang disebut asisten (*teacher assistant*) di antara guru dan *student*. Dalam skema aslinya, distilasi dilakukan secara bertahap, yaitu dari guru besar ke asisten, kemudian dari asisten ke *student*.

Dengan adanya asisten berkapasitas menengah, selisih kapasitas pada setiap tahap distilasi menjadi lebih kecil, sehingga pengetahuan dapat ditransfer secara lebih efektif (Mirzadeh dkk., 2020). Pada penelitian ini, Focus-RCNet berkapasitas menengah dilatih secara mandiri dengan label keras dan berperan sebagai guru langsung bagi *student* WasteNet. Posisi ketiga strategi distilasi yang dibandingkan, yaitu distilasi langsung dari guru besar, distilasi melalui asisten menengah, dan *self-distillation* dengan guru berkapasitas sama, di sepanjang kurva *capacity gap* diilustrasikan pada Gambar 2.3.


(a) Direct KD



(b) Teacher-Assistant KD



(c) Self-Distillation (BAN)



Gambar 2.3 Strategi Distilasi pada Kurva Capacity Gap

2.2.8 Self-Distillation (Born-Again Networks)

Self-distillation merupakan varian *knowledge distillation* yang menggunakan model dengan arsitektur dan kapasitas yang sama sebagai guru bagi dirinya sendiri (Furlanello dkk., 2018). Pendekatan *Born-Again Networks* (BAN) menerapkan

distilasi secara berurutan antargenerasi, yaitu model generasi pertama dilatih secara konvensional, kemudian menjadi guru bagi model generasi kedua yang memiliki arsitektur identik, dan seterusnya. Meskipun guru dan *student* memiliki kapasitas yang sama, *soft label* dari guru tetap membawa informasi tambahan yang membantu *student* mencapai performa yang setara atau bahkan lebih baik.

Furlanello dkk. (2018) menunjukkan bahwa efek *self-distillation* sebagian besar berasal dari fungsi regularisasi *soft label* yang menghaluskan target pelatihan dan mengurangi *overfitting*. Pada penelitian ini, pendekatan BAN ditempatkan sebagai titik ujung kurva *capacity gap*, yaitu kondisi saat kapasitas guru sama dengan *student*, dengan WasteNet generasi sebelumnya bertindak sebagai guru bagi WasteNet generasi berikutnya. Perbandingan BAN terhadap distilasi dari guru besar dan asisten menengah memungkinkan analisis menyeluruh mengenai pengaruh kapasitas guru terhadap efektivitas distilasi.

2.2.9 Preprocessing Citra

Preprocessing citra merupakan tahap penyiapan data citra sebelum digunakan pada pelatihan dan pengujian model *deep learning* (Gonzalez & Woods, 2018). Tahap ini bertujuan menyeragamkan karakteristik citra serta memastikan kesesuaian format masukan dengan kebutuhan arsitektur jaringan. Pada klasifikasi citra sampah, *preprocessing* umumnya meliputi konversi kanal warna ke format RGB dan penyesuaian ukuran citra (*resizing*) agar seragam, karena model CNN hanya menerima masukan dengan dimensi tertentu (Krizhevsky dkk., 2012). Penyeragaman ukuran citra juga membantu mengurangi beban komputasi tanpa menghilangkan pola visual utama yang dibutuhkan untuk klasifikasi.

Tahap *preprocessing* berikutnya adalah normalisasi nilai piksel untuk menyamakan skala intensitas citra serta mempercepat dan menstabilkan proses konvergensi pelatihan (Goodfellow dkk., 2016). Normalisasi umumnya dilakukan dengan menyesuaikan distribusi nilai piksel menggunakan nilai rata-rata dan simpangan baku, sebagaimana dirumuskan pada Persamaan (2.3).

$$x' = \frac{x - \mu}{\sigma} \quad (2.3)$$


dengan x' merupakan nilai piksel hasil normalisasi, x adalah nilai piksel asli, μ adalah nilai rata-rata, dan σ adalah simpangan baku (Gonzalez & Woods, 2018). Pada penelitian ini, nilai rata-rata dan simpangan baku yang digunakan mengikuti statistik dataset ImageNet agar konsisten dengan bobot pelatihan model guru.

2.2.10 Data Augmentation

Data augmentation merupakan teknik untuk meningkatkan jumlah dan variasi data pelatihan dengan menerapkan transformasi tertentu pada data yang sudah ada tanpa mengubah labelnya (Shorten & Khoshgoftaar, 2019). Teknik ini penting dalam *deep learning* karena performa model sangat dipengaruhi oleh keragaman data pelatihan (Goodfellow dkk., 2016). Pada dataset dengan jumlah citra terbatas

seperti TrashNet, *data augmentation* membantu model mempelajari representasi fitur yang lebih *robust* serta mengurangi risiko *overfitting* (Perez & Wang, 2017). Augmentasi umumnya diterapkan hanya pada data latih, sehingga data validasi dan data uji tetap merepresentasikan kondisi citra asli.

Berbagai teknik *data augmentation* yang umum digunakan pada klasifikasi citra antara lain pencerminan (*flip*), penyesuaian kecerahan dan kontras, serta penghapusan sebagian wilayah citra secara acak (*coarse dropout*) (Buslaev dkk., 2020). Transformasi tersebut bertujuan mensimulasikan variasi kondisi nyata saat pengambilan citra, seperti perbedaan orientasi objek dan pencahayaan. Contoh penerapan beberapa teknik *data augmentation* pada sebuah citra ditunjukkan pada Gambar 2.4.




Gambar 2.4 Ilustrasi Teknik Data Augmentation

2.2.11 Dataset TrashNet

Dataset TrashNet merupakan dataset publik citra sampah yang diperkenalkan oleh Thung dan Yang (2016) dari Universitas Stanford dan telah banyak digunakan sebagai tolok ukur dalam penelitian klasifikasi sampah. Dataset ini berisi 2.527 citra yang telah dilabeli dan diklasifikasikan ke dalam enam kelas, yaitu *cardboard* (kardus), *glass* (kaca), *metal* (logam), *paper* (kertas), *plastic* (plastik), dan *trash* (sampah lain). Setiap citra diambil dengan latar belakang putih dan pencahayaan yang dikontrol, sehingga memberikan kondisi yang representatif untuk tugas klasifikasi citra sampah. Dataset bersifat *open-access* dan tersedia dalam varian *dataset-resized* yang telah diseragamkan ukurannya.

Distribusi jumlah citra pada setiap kelas dataset TrashNet tidak sepenuhnya seimbang, sebagaimana ditunjukkan pada Gambar 2.5. Kelas *paper* memiliki jumlah citra terbanyak, sedangkan kelas *trash* memiliki jumlah citra paling sedikit karena bersifat heterogen sebagai kategori penampung.



Gambar 2.5 Distribusi Jumlah Citra per Kelas pada Dataset TrashNet (Thung & Yang, 2016)

Karena karakteristiknya yang heterogen dan jumlahnya yang jauh lebih sedikit, kelas *trash* berpotensi menyulitkan proses klasifikasi. Oleh karena itu, penelitian ini menggunakan dua skema label, yaitu skema enam kelas (K6) yang mempertahankan seluruh kelas dan skema lima kelas (K5) yang menghilangkan kelas *trash*. Penggunaan kedua skema ini bertujuan untuk menganalisis pengaruh keberadaan kelas penampung terhadap performa dan efektivitas distilasi pada model ringan WasteNet.

2.2.12 Evaluasi Model Klasifikasi

Evaluasi model merupakan tahap penting untuk mengukur kinerja sistem klasifikasi citra sampah secara objektif. Evaluasi tidak hanya bertujuan mengetahui ketepatan prediksi model, tetapi juga menilai kemampuan model membedakan setiap kelas secara seimbang, terutama pada dataset dengan distribusi kelas yang tidak seimbang (Sokolova & Lapalme, 2009). Oleh karena itu, evaluasi pada penelitian ini dilakukan menggunakan beberapa metrik klasifikasi yang umum digunakan, yaitu *confusion matrix*, *accuracy*, *precision*, *recall*, dan *F1-score* (Powers, 2011).

2.2.14.1 Confusion Matrix

Confusion matrix merupakan tabel evaluasi yang menggambarkan perbandingan antara label aktual dan label hasil prediksi model, sehingga memberikan informasi rinci mengenai jumlah prediksi benar dan salah pada setiap kelas (Sokolova & Lapalme, 2009). Karena penelitian ini bersifat multikelas, evaluasi dilakukan secara *one-vs-rest* dengan empat komponen utama untuk setiap kelas, yaitu:

- *True Positive* (TP): jumlah citra suatu kelas yang diprediksi benar sebagai kelas tersebut;
- *True Negative* (TN): jumlah citra bukan kelas tersebut yang diprediksi benar sebagai bukan kelas tersebut;

- *False Positive* (FP): jumlah citra bukan kelas tersebut yang keliru diprediksi sebagai kelas tersebut;
- *False Negative* (FN): jumlah citra suatu kelas yang keliru diprediksi sebagai kelas lain.

Confusion matrix menjadi dasar dalam perhitungan metrik evaluasi lainnya dan penting untuk memahami jenis kesalahan yang dilakukan model (Chicco & Jurman, 2020).

2.2.14.2 Accuracy

Accuracy mengukur proporsi prediksi yang benar terhadap keseluruhan data uji dan sering digunakan sebagai indikator awal performa model klasifikasi (Powers, 2011). Nilai *accuracy* dihitung menggunakan Persamaan (2.4).

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.4)$$

Meskipun mudah dipahami, *accuracy* sebaiknya tidak digunakan sebagai satu-satunya indikator pada dataset dengan distribusi kelas tidak seimbang, karena dapat memberikan gambaran yang menyesatkan (Sokolova & Lapalme, 2009).

2.2.14.3 Precision

Precision menunjukkan tingkat ketepatan model dalam memprediksi suatu kelas dengan membandingkan jumlah prediksi benar terhadap seluruh prediksi positif yang dihasilkan model untuk kelas tersebut (Powers, 2011). Nilai *precision* yang tinggi menandakan rendahnya kesalahan *false positive*. Nilai *precision* dihitung menggunakan Persamaan (2.5).

$$Precision = \frac{TP}{TP + FP} \quad (2.5)$$

2.2.14.4 Recall

Recall atau sensitivitas mengukur kemampuan model dalam mendeteksi seluruh citra yang sebenarnya termasuk dalam suatu kelas (Sokolova & Lapalme, 2009). Nilai *recall* yang tinggi menandakan rendahnya kesalahan *false negative*. Nilai *recall* dihitung menggunakan Persamaan (2.6).

$$Recall = \frac{TP}{TP + FN} \quad (2.6)$$

2.2.14.5 F1-Score

F1-score merupakan metrik yang menggabungkan *precision* dan *recall* dalam satu nilai rata-rata harmonis, sehingga memberikan keseimbangan antara ketepatan prediksi dan kemampuan deteksi (Powers, 2011). Metrik ini sangat sesuai untuk dataset dengan distribusi kelas tidak seimbang karena mempertimbangkan *false positive* dan *false negative* secara bersamaan (Chicco & Jurman, 2020). Nilai *F1-score* dihitung menggunakan Persamaan (2.7).

$$F1\text{-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.7)$$

Karena penelitian ini melibatkan klasifikasi multikelas, metrik utama yang digunakan adalah *accuracy* dan *macro F1-score*, yaitu rata-rata *F1-score* seluruh kelas yang memberi bobot setara pada setiap kelas tanpa mempertimbangkan jumlah sampelnya. Penggunaan *macro F1-score* bertujuan memberikan gambaran performa yang adil terhadap kelas dengan jumlah sampel lebih sedikit, seperti kelas *trash*. Selain metrik agregat tersebut, nilai F1 setiap kelas juga ditelaah secara terpisah untuk mengetahui pada kelas mana perbaikan akibat distilasi terjadi, sebab perbaikan yang terkonsentrasi pada kelas-kelas yang saling menyerupai merupakan indikasi berpindahnya informasi kemiripan antarkelas dari guru ke student.

Selain kualitas klasifikasi, penelitian ini juga menilai efisiensi komputasi model sebagai indikator kelayakan penerapan pada perangkat dengan sumber daya terbatas. Efisiensi diukur melalui dua besaran, yaitu jumlah parameter dan FLOPs (*floating-point operations*), yakni banyaknya operasi bilangan titik-mengambang yang diperlukan untuk satu kali inferensi. Jumlah parameter mencerminkan ukuran model dan kebutuhan memori, sedangkan FLOPs mencerminkan beban komputasi pada saat inferensi; keduanya bersifat statis terhadap arsitektur sehingga dapat dihitung tanpa bergantung pada proses pelatihan. Pada resolusi masukan 160×160 piksel, WasteNet-128K memiliki sekitar 128 ribu parameter dengan beban komputasi sekitar 51 juta FLOPs (setara dengan ≈25,6 juta MACs), sedangkan WasteNet-256K memiliki sekitar 256 ribu parameter dengan sekitar 84 juta FLOPs (≈41,8 juta MACs). Nilai FLOPs yang sangat kecil ini menegaskan bahwa WasteNet dirancang untuk beban komputasi rendah sehingga sesuai diterapkan pada perangkat dengan keterbatasan komputasi.

2.2.13 Uji Statistik

Uji statistik digunakan untuk memastikan bahwa perbedaan performa antarskenario distilasi tidak terjadi secara kebetulan, melainkan benar-benar signifikan secara statistik (Dietterich, 1998). Dalam membandingkan dua model klasifikasi, diperlukan uji yang sesuai dengan sifat data hasil eksperimen agar kesimpulan yang ditarik dapat dipertanggungjawabkan. Penelitian ini menggunakan kombinasi beberapa uji statistik yang saling melengkapi, baik pada tingkat antar-*seed* maupun pada tingkat sampel uji (Demšar, 2006).

Pada tingkat antar-*seed*, digunakan *paired t-test* dan *Wilcoxon signed-rank test* yang membandingkan akurasi lima *seed* pada dua skenario yang identik kecuali pada satu faktor yang diuji. *Paired t-test* mengasumsikan distribusi normal pada selisih kedua skenario, sedangkan *Wilcoxon signed-rank test* merupakan uji nonparametrik yang tidak bergantung pada asumsi tersebut sehingga lebih *robust* terhadap jumlah sampel yang kecil (Demšar, 2006). Penggunaan kedua uji secara bersamaan bertujuan memperkuat keabsahan kesimpulan.

Pada tingkat sampel uji, digunakan *McNemar test* dengan koreksi kontinuitas yang membandingkan pola benar-salah dua model pada data uji yang sama (Dietterich, 1998). Uji ini berfokus pada sampel-sampel yang diklasifikasikan berbeda oleh kedua model, sehingga sesuai untuk membandingkan dua pengklasifikasi pada satu himpunan data uji. Tingkat signifikansi yang digunakan pada seluruh pengujian adalah 0,05, dan suatu strategi distilasi dinyatakan unggul hanya apabila keunggulannya konsisten pada berbagai uji yang diterapkan.

BAB 3

METODE PENELITIAN

3.1 Pendekatan, Jenis, dan Prosedur Penelitian

Bab ini menjelaskan metodologi penelitian yang digunakan dalam pengembangan model ringan untuk klasifikasi citra sampah berbasis *knowledge distillation*. Metodologi penelitian disusun secara sistematis untuk memastikan bahwa proses penelitian dapat dilakukan secara terstruktur, terukur, dan dapat dipertanggungjawabkan secara ilmiah. Pembahasan pada bab ini mencakup pendekatan penelitian, jenis penelitian, serta prosedur penelitian yang digunakan dari tahap awal hingga evaluasi model. Metodologi yang tepat sangat penting untuk mendukung pencapaian tujuan penelitian yang telah dirumuskan pada Bab I.

3.1.1 Pendekatan Penelitian

Pendekatan penelitian merupakan kerangka metodologis yang mendasari pelaksanaan suatu studi ilmiah, mencakup pola pikir, strategi, serta prosedur yang diterapkan mulai dari perumusan masalah hingga penarikan kesimpulan (Sugiyono, 2015). Pendekatan ini berperan penting dalam menentukan cara data dikumpulkan, diolah, dianalisis, dan diinterpretasikan untuk menjawab tujuan penelitian. Penelitian ini menggunakan pendekatan kuantitatif, karena data yang dianalisis berupa citra sampah yang direpresentasikan dalam bentuk nilai numerik dan dievaluasi menggunakan metrik statistik yang terukur.

Pendekatan kuantitatif dipilih karena penelitian ini menggunakan angka dan statistik untuk mengumpulkan data yang presisi dan terukur, di mana metode kuantitatif memungkinkan pengukuran variabel secara sistematis dan pengujian hipotesis (Sugiyono, 2015). Penelitian ini berfokus pada pengukuran performa model *deep learning* dalam melakukan klasifikasi citra secara objektif. Citra sampah diolah melalui proses komputasi untuk menghasilkan keluaran berupa prediksi kelas, yang selanjutnya dievaluasi menggunakan metrik seperti *accuracy*, *precision*, *recall*, dan *F1-score*, serta diperkuat dengan uji signifikansi statistik untuk membandingkan antarskenario. Penggunaan pendekatan kuantitatif pada penelitian berbasis *deep learning* telah banyak diterapkan dan terbukti efektif dalam analisis citra (Goodfellow dkk., 2016).


3.1.2 Jenis Penelitian

Jenis penelitian yang digunakan dalam penelitian ini adalah penelitian eksperimental yang bersifat komparatif. Penelitian eksperimental dilakukan dengan cara membangun, melatih, dan menguji model *deep learning* untuk mengklasifikasikan citra sampah berdasarkan kelas yang telah ditentukan. Jenis penelitian ini dipilih karena memberikan keleluasaan bagi peneliti untuk mengevaluasi pengaruh berbagai strategi *knowledge distillation* serta jenis guru terhadap kinerja model *student* yang ringan.

Melalui pendekatan eksperimental, penelitian ini membandingkan beberapa strategi distilasi secara *head-to-head*, yaitu *direct knowledge distillation* dari guru besar, *teacher-assistant knowledge distillation* dari guru menengah, serta *self-distillation* dengan guru berkapasitas sama. Seluruh skenario dilatih dan dievaluasi menggunakan dataset, protokol pembagian data, dan konfigurasi pelatihan yang identik, sehingga perbedaan performa yang diperoleh benar-benar disebabkan oleh perbedaan strategi distilasi yang diuji, bukan oleh faktor lain.

3.1.3 Prosedur Penelitian

Prosedur penelitian ini dirancang secara sistematis untuk menghasilkan model *student* ringan dengan kinerja optimal sesuai dengan tujuan penelitian. Tahapan penelitian diawali dengan studi literatur, dilanjutkan dengan perumusan masalah, pengumpulan dan pengelolaan data, perancangan dan pelatihan model, evaluasi serta analisis hasil, dan diakhiri dengan penarikan kesimpulan. Seluruh rangkaian prosedur penelitian disajikan secara ringkas dalam bentuk diagram alir pada Gambar 3.1.



Gambar 3.6 Diagram Alir Prosedur Penelitian

3.1.3.1 Studi Literatur

Studi literatur merupakan tahap awal penelitian yang bertujuan untuk memperoleh pemahaman teoretis dan empiris terkait klasifikasi citra sampah, *deep learning*, serta *knowledge distillation*. Pada tahap ini dilakukan penelusuran terhadap artikel jurnal ilmiah, prosiding konferensi, dan publikasi penelitian terdahulu yang relevan. Fokus kajian diarahkan pada metode distilasi pengetahuan, fenomena *capacity gap* antara guru dan *student*, serta teknik kompresi model. Hasil studi literatur digunakan sebagai dasar dalam menentukan pendekatan dan metodologi yang diterapkan.

3.1.3.2 Perumusan Masalah

Perumusan masalah dilakukan berdasarkan hasil studi literatur yang telah dianalisis secara kritis. Tahap ini bertujuan untuk mendefinisikan permasalahan penelitian secara jelas dan terukur, khususnya keterbatasan transfer pengetahuan

dari guru berkapasitas besar ke *student* ringan akibat *capacity gap*. Rumusan masalah menjadi acuan utama dalam menentukan tujuan, ruang lingkup, serta strategi distilasi yang akan dibandingkan dalam penelitian.

3.1.3.3 Pengumpulan dan Pengelolaan Data

Tahap pengumpulan dan pengelolaan data dilakukan dengan memanfaatkan dataset publik citra sampah TrashNet yang telah banyak digunakan dalam penelitian sebelumnya. Setelah data dikumpulkan, dilakukan pengelolaan data yang meliputi penghapusan duplikat, pembagian data ke dalam himpunan latih, validasi, dan uji, serta penyusunan *manifest per-seed* agar pembagian data bersifat deterministik dan dapat direplikasi. Pengelolaan data yang baik bertujuan untuk memastikan data siap digunakan dan menghasilkan evaluasi yang objektif.

3.1.3.4 Perancangan dan Pelatihan Model

Tahap ini meliputi perancangan tiga peran model, yaitu guru besar (EfficientNet-B4), asisten berkapasitas menengah (Focus-RCNet), dan *student* ringan (WasteNet), serta pelatihan seluruh skenario distilasi. Setiap *student* dilatih menggunakan strategi distilasi yang berbeda dengan konfigurasi pelatihan yang identik untuk menjamin objektivitas perbandingan. Proses pelatihan dilakukan secara berulang pada lima *seed* untuk memperoleh hasil yang stabil dan dapat diuji secara statistik.

3.1.3.5 Evaluasi dan Analisis

Model yang telah dilatih dievaluasi menggunakan data uji untuk mengukur performa klasifikasi secara objektif berdasarkan *accuracy* dan *macro F1-score*. Hasil setiap skenario kemudian dibandingkan dan diuji signifikansinya menggunakan uji statistik berpasangan. Tahap analisis bertujuan untuk mengetahui strategi distilasi dan jenis guru yang paling efektif dalam meningkatkan kinerja *student* ringan.

3.1.3.6 Kesimpulan dan Saran

Tahap kesimpulan dan saran merupakan tahap akhir penelitian. Kesimpulan disusun berdasarkan hasil analisis dan evaluasi model, dengan merangkum temuan utama mengenai pengaruh kapasitas guru terhadap keberhasilan distilasi. Selain itu, disusun pula saran sebagai rekomendasi untuk penelitian selanjutnya, sehingga penelitian diharapkan memberikan kontribusi akademik dan praktis di bidang kompresi model untuk klasifikasi citra sampah.

3.2 Lokasi dan Waktu Penelitian

Penelitian ini dilaksanakan di lingkungan akademik Program Studi Teknik Informatika, Universitas Negeri Semarang, dengan seluruh proses pengolahan data, eksperimen model, dan penyusunan laporan dilakukan menggunakan sumber daya komputasi awan. Implementasi model dan eksperimen dilakukan menggunakan bahasa pemrograman Python dengan *framework deep learning* PyTorch beserta

pustaka *timm* dan *Albumentations*, serta dijalankan pada lingkungan Kaggle Notebook yang menyediakan akselerator GPU.

Adapun waktu pelaksanaan penelitian berlangsung sejak September 2025 hingga Juni 2026, yang mencakup tahap perumusan topik, studi literatur, penyusunan metodologi, implementasi dan pelatihan model, evaluasi performa, hingga analisis hasil dan penyelesaian dokumen skripsi. Rentang waktu ini dipilih agar seluruh proses penelitian dapat dilakukan secara bertahap, terukur, dan sistematis sesuai standar akademik yang ditetapkan oleh Universitas Negeri Semarang.

3.3 Subjek Penelitian/Sampel dan Populasi

Proses klasifikasi citra sampah menggunakan model *deep learning* ringan menjadi subjek utama pada penelitian ini. Subjek ini memiliki relevansi tinggi dalam mendukung sistem pemilahan sampah otomatis yang efisien, khususnya pada perangkat dengan keterbatasan komputasi. Tujuan penelitian ini adalah mengembangkan model *student* ringan WasteNet yang akurat melalui *knowledge distillation*, sehingga dapat membedakan jenis sampah secara cepat dan konsisten.

Populasi penelitian mencakup seluruh citra sampah yang tersedia dalam dataset publik TrashNet, dengan enam kategori jenis sampah. Sampel penelitian terdiri atas subset citra yang dipilih secara sistematis dari populasi tersebut dan dibagi ke dalam data latih, validasi, dan uji. Untuk menganalisis pengaruh jumlah kelas, penelitian ini menggunakan dua skema label, yaitu skema enam kelas (K6) dan skema lima kelas (K5) yang menghilangkan kelas *trash*.

3.4 Data dan Sumber Data

Sumber data dalam penelitian ini berasal dari dataset publik TrashNet yang diperkenalkan oleh Thung dan Yang (2016) dari Universitas Stanford. Dataset ini berisi 2.527 citra sampah yang telah dilabeli dan diklasifikasikan ke dalam enam kelas, yaitu *cardboard* (kardus), *glass* (kaca), *metal* (logam), *paper* (kertas), *plastic* (plastik), dan *trash* (sampah lain). Setiap citra diambil dengan latar belakang putih dan pencahayaan yang dikontrol, sehingga memberikan kondisi yang representatif untuk tugas klasifikasi citra sampah.

Dataset TrashNet bersifat *open-access* dan dapat diunduh melalui platform Kaggle, sehingga memungkinkan replikasi dan validasi penelitian secara terbuka. Penelitian ini menggunakan varian *dataset-resized* yang telah diseragamkan ukurannya. Berdasarkan dataset enam kelas tersebut, disusun dua skema label, yaitu K6 yang mempertahankan seluruh enam kelas dan K5 yang menghilangkan kelas *trash* karena bersifat heterogen sebagai kategori penampung. Kedua skema diproses dengan protokol yang identik kecuali pada jumlah kelas.

3.5 Teknik Pengumpulan Data

Pengumpulan data dilakukan melalui proses eksplorasi dan seleksi dataset publik citra sampah yang telah divalidasi dalam berbagai penelitian klasifikasi sampah. Berdasarkan hasil kajian literatur, dipilih dataset TrashNet sebagai sumber data utama karena telah menjadi tolok ukur (*benchmark*) dan memiliki label kelas yang jelas. Proses pengunduhan dataset dilakukan secara langsung melalui platform penyedia dataset publik, kemudian data diperiksa untuk memastikan kelengkapan, konsistensi format citra, serta kesesuaian label.

Setelah pengunduhan, dilakukan pemeriksaan duplikasi untuk menghapus citra yang identik maupun berkonflik antarlabel, sehingga setiap citra hanya muncul satu kali pada satu himpunan data. Selanjutnya disusun berkas *manifest* yang mencatat identitas, lintasan, label, serta himpunan (latih/validasi/uji) untuk setiap citra pada masing-masing *seed*. Penyusunan *manifest* ini menjamin bahwa pembagian data bersifat deterministik dan identik di seluruh skenario distilasi, sehingga perbandingan antarmodel menjadi adil.


3.6 Teknik Keabsahan Data

Validitas dan reliabilitas dataset TrashNet diperkuat oleh pemanfaatannya secara luas sebagai tolok ukur standar dalam berbagai penelitian klasifikasi citra sampah sejak diperkenalkan oleh Thung dan Yang (2016). Konsistensi penggunaan dataset ini pada banyak penelitian menunjukkan bahwa data yang digunakan memiliki tingkat keabsahan yang tinggi dan layak dijadikan dasar pengembangan model. Selain itu, keabsahan proses penelitian dijaga melalui protokol pembagian data yang deterministik, pengulangan eksperimen pada lima *seed*, serta evaluasi pada data uji yang sepenuhnya terpisah dari proses pelatihan.

3.7 Teknik Analisis Data

Teknik analisis data dalam penelitian ini dilakukan melalui serangkaian tahapan komputasional yang bertujuan untuk membangun, melatih, dan mengevaluasi model klasifikasi citra sampah secara sistematis. Analisis data diawali dengan *import* dataset, dilanjutkan dengan *preprocessing* untuk menyeragamkan format citra, kemudian pembagian data, augmentasi, perancangan arsitektur model, penerapan *knowledge distillation*, pelatihan, evaluasi, hingga pengujian signifikansi statistik.

Seluruh tahapan dirancang agar setiap skenario distilasi dilatih dan dievaluasi pada kondisi yang identik, sehingga perbedaan performa benar-benar mencerminkan pengaruh strategi distilasi dan jenis guru. Tahap akhir teknik analisis data adalah penyusunan skenario pengujian untuk membandingkan performa antarmodel secara menyeluruh. Seluruh tahapan tersebut disajikan dalam bentuk diagram alir pada Gambar 3.2.



Gambar 3.7 Diagram Alir Teknik Analisis Data

3.7.1 Import Dataset

Tahap *import* dataset merupakan langkah awal dalam alur penelitian sebagaimana ditunjukkan pada diagram alir. Pada tahap ini, seluruh citra sampah dimuat ke dalam lingkungan pemrograman Python menggunakan pustaka pengolahan citra dan *deep learning*. Pemuatan data dilakukan berdasarkan berkas *manifest* hasil tahap pengumpulan data, yang memetakan setiap citra ke label dan himpunnanya. Pada tahap ini juga dilakukan pengecekan awal terhadap struktur direktori, jumlah data pada setiap kelas, serta kesesuaian antara citra dan label untuk memastikan dataset siap diproses.

3.7.2 Preprocessing

Tahap *preprocessing* merupakan proses penyiapan citra sampah sebelum digunakan pada pelatihan dan pengujian model. *Preprocessing* bertujuan untuk menyeragamkan karakteristik citra serta memastikan kesesuaian format masukan dengan kebutuhan arsitektur jaringan. Secara garis besar, proses *preprocessing* yang dilakukan meliputi konversi kanal warna, penyesuaian ukuran citra, dan normalisasi nilai piksel.

- *Konversi RGB*, yaitu memastikan seluruh citra berada dalam tiga kanal warna (RGB) agar kompatibel dengan arsitektur jaringan yang mengharapkan masukan tiga kanal.
- *Resizing*, yaitu penyesuaian ukuran citra mengikuti kebutuhan masing-masing model. Citra masukan model guru dan asisten diubah ke ukuran 380 x 380 piksel, sedangkan citra masukan model *student* WasteNet diubah ke ukuran 160 x 160 piksel untuk menjaga efisiensi komputasi. Khusus pada skenario distilasi, resolusi masukan guru/asisten saat menghasilkan *soft label* disesuaikan dengan kapasitas student dan dipilih melalui *pilot*, yaitu 160 x 160 piksel untuk student 128K dan

380 x 380 piksel untuk student 256K. Pada self-distillation, guru berkapasitas sama (WasteNet) beroperasi pada 160 x 160 piksel.

- *Normalization*, yaitu penskalaan nilai piksel menggunakan nilai rata-rata dan simpangan baku ImageNet. Normalisasi ini menstabilkan dan mempercepat konvergensi selama pelatihan serta mengurangi risiko ketidakstabilan gradien.

3.7.3 Data Splitting

Tahap *data splitting* dilakukan untuk membagi dataset citra sampah ke dalam beberapa subset yang digunakan pada proses pelatihan dan evaluasi model. Pembagian data bertujuan untuk mengukur kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya. Pembagian dilakukan secara *stratified* sehingga proporsi setiap kelas terjaga pada seluruh himpunan, dengan proporsi sebagai berikut:

- 70% data latih (*training set*);
- 15% data validasi (*validation set*);
- 15% data uji (*testing set*).

Pembagian data dilakukan secara deterministik berdasarkan *seed* dan dicatat dalam berkas *manifest*, sehingga seluruh skenario distilasi menggunakan komposisi data yang persis sama. Himpunan validasi digunakan untuk pemilihan *checkpoint* terbaik, sedangkan himpunan uji hanya digunakan satu kali pada tahap pelaporan akhir untuk menjaga objektivitas evaluasi.

Proses pelatihan dan evaluasi diulang menggunakan lima seed yang berbeda (42, 123, 777, 2026, dan 3407), yang masing-masing menghasilkan pembagian data acak yang berbeda pula. Skema pengulangan ini berfungsi sebagai validasi silang berulang (*repeated cross-validation*), sehingga estimasi performa tidak bergantung pada satu pembagian data yang kebetulan menguntungkan, melainkan dirata-ratakan atas lima pembagian yang berbeda beserta simpangan bakunya. Dengan demikian, protokol ini memberikan kestabilan estimasi yang setara dengan validasi silang, sekaligus tetap mempertahankan himpunan uji yang terpisah pada setiap pengulangan.

3.7.4 Data Augmentation

Tahap *data augmentation* dilakukan untuk meningkatkan variasi data latih serta mengurangi risiko *overfitting*. Augmentasi diterapkan hanya pada data latih, sehingga data validasi dan data uji tetap merepresentasikan kondisi citra asli tanpa modifikasi. Transformasi acak diterapkan pada setiap *batch* selama pelatihan, sehingga model memperoleh variasi data yang berbeda pada setiap *epoch*. Transformasi yang digunakan meliputi:


- *Horizontal Flip*, yaitu pencerminan citra secara horizontal dengan peluang 0,5;

- *Vertical Flip*, yaitu pencerminan citra secara vertikal dengan peluang 0,5;
- *Random Brightness Contrast*, yaitu penyesuaian kecerahan dan kontras citra secara acak untuk mensimulasikan variasi pencahayaan;
- *Coarse Dropout*, yaitu penghapusan sebagian wilayah citra secara acak untuk mendorong model mempelajari fitur yang lebih kuat dan tidak bergantung pada satu wilayah tertentu.

3.7.5 Arsitektur Model

Penelitian ini melibatkan tiga peran model dengan kapasitas berbeda yang berperan dalam skema *knowledge distillation*. Ketiganya digunakan untuk menguji pengaruh kapasitas guru terhadap keberhasilan transfer pengetahuan ke model *student* yang ringan. Arsitektur masing-masing model dijelaskan sebagai berikut:

- *Guru besar* (EfficientNet-B4), yaitu model berkapasitas besar dengan sekitar 17,6 juta parameter yang dilatih menggunakan bobot pralatih ImageNet. Model ini berperan sebagai sumber pengetahuan dengan performa tertinggi sekaligus batas atas kinerja.
- *Asisten* (Focus-RCNet), yaitu model berkapasitas menengah dengan sekitar 520 ribu parameter. Model ini berperan sebagai guru perantara (*teacher assistant*) yang menjembatani selisih kapasitas antara guru besar dan *student*.
- *Student* (WasteNet), yaitu model ringan yang menjadi sasaran akhir penelitian. Dua varian kapasitas digunakan, yaitu WasteNet-128K (sekitar 128 ribu parameter) dan WasteNet-256K (sekitar 256 ribu parameter), untuk menganalisis pengaruh kapasitas *student* terhadap efektivitas distilasi.



Gambar 3.8 Arsitektur Model Guru, Asisten, dan Student

3.7.6 Knowledge Distillation

Knowledge distillation merupakan teknik kompresi model yang melatih model *student* berukuran kecil untuk menirukan keluaran model guru yang lebih besar

(Hinton et al., 2015). Selain mempelajari label sebenarnya melalui *hard label*, *student* juga mempelajari distribusi probabilitas keluaran guru (*soft label*) yang dihaluskan menggunakan parameter suhu (*temperature*). Distribusi *soft label* tersebut membawa *dark knowledge*, yaitu informasi kemiripan antarkelas yang tidak terdapat pada *hard label*. Fungsi kerugian total merupakan kombinasi berbobot antara *cross-entropy* terhadap label sebenarnya dan divergensi Kullback-Leibler terhadap *soft label* guru, dengan koefisien pembobotan alfa, sebagaimana ditunjukkan pada Persamaan (3.1).

$$L_{KD} = (1 - \alpha) L_{CE} + \alpha T^2 D_{KL}(p_t // p_s)$$

dengan L_{KD} merupakan fungsi kerugian total *knowledge distillation*, L_{CE} adalah fungsi *cross-entropy* terhadap label sebenarnya, D_{KL} adalah divergensi Kullback-Leibler terhadap *soft label* guru, α adalah koefisien pembobotan ($0 \leq \alpha \leq 1$), T adalah parameter suhu (*temperature*), serta p_t dan p_s merupakan distribusi probabilitas keluaran guru dan *student*.

Untuk menguji pengaruh kapasitas guru, penelitian ini membandingkan tiga strategi distilasi. *Pertama*, *direct knowledge distillation* yang mendistilasi pengetahuan langsung dari guru besar EfficientNet-B4 ke *student* (Hinton et al., 2015). *Kedua*, *teacher-assistant knowledge distillation* (TA-KD) yang menggunakan asisten berkapasitas menengah Focus-RCNet sebagai guru perantara untuk mengurangi *capacity gap* antara guru dan *student* (Mirzadeh et al., 2020). *Ketiga*, *self-distillation* dengan pendekatan *Born-Again Networks* (BAN) yang menggunakan model berkapasitas sama, yaitu WasteNet generasi sebelumnya, sebagai guru (Furlanello et al., 2018). Ketiga strategi ini ditempatkan pada satu kurva *capacity gap* untuk menguji hipotesis bahwa guru berkapasitas menengah lebih efektif dibandingkan guru besar maupun guru berkapasitas sama (Cho & Hariharan, 2019).

3.7.7 Training Model

Tahap pelatihan model merupakan proses pembelajaran utama dalam penelitian ini. Seluruh model dilatih menggunakan *optimizer* Stochastic Gradient Descent (SGD) dengan *momentum* 0,9 dan *weight decay* sebesar 1×10^{-4} , serta penjadwalan laju pembelajaran *cosine annealing*. Pelatihan dilakukan selama 100 *epoch* tanpa *early stopping*, dengan pemilihan *checkpoint* terbaik berdasarkan akurasi tertinggi pada data validasi. Untuk meningkatkan efisiensi, pelatihan memanfaatkan *automatic mixed precision*. Nilai parameter suhu (T), koefisien pembobotan distilasi (α), resolusi masukan asisten, dan laju pembelajaran ditentukan terlebih dahulu melalui tahap uji pendahuluan (*pilot*) menggunakan satu seed (seed 42) pada data validasi. Kombinasi terbaik kemudian dibekukan dan diterapkan secara seragam pada seluruh eksperimen lima seed, sehingga data uji tidak pernah dilibatkan dalam pemilihan parameter dan objektivitas evaluasi tetap terjaga.

Guna memperoleh hasil yang stabil dan dapat diuji secara statistik, setiap skenario dilatih secara berulang menggunakan lima *seed* (42, 123, 777, 2026, dan 3407). Pada strategi TA-KD, pelatihan dilakukan dalam dua tahap (*two-stage*), yaitu pralatih menggunakan *cross-entropy* yang dilanjutkan dengan penyetelan halus menggunakan distilasi. Seluruh konfigurasi pelatihan dijaga identik di semua skenario, kecuali pada faktor yang sedang diuji, sehingga perbedaan performa benar-benar mencerminkan pengaruh strategi distilasi. Asisten Focus-RCNet yang digunakan sebagai guru pada strategi TA-KD dilatih menggunakan *cross-entropy*. Sebagai studi ablasi, cara pelatihan asisten juga diuji dengan mendistilasi Focus-RCNet dari EfficientNet-B4, baik satu tahap maupun dua tahap; perbedaannya terhadap performa student tidak signifikan secara statistik sehingga asisten hasil pelatihan *cross-entropy* dipilih untuk pelaporan.

3.7.8 Model Evaluation

Evaluasi model dilakukan menggunakan model terbaik yang diperoleh berdasarkan performa pada data validasi, kemudian diuji pada data uji yang sepenuhnya terpisah dari proses pelatihan. Kinerja model dievaluasi menggunakan *confusion matrix* yang menyajikan perbandingan antara kelas aktual dan kelas hasil prediksi. Untuk pendekatan multikelas, evaluasi dilakukan secara *one-vs-rest* dengan komponen *True Positive* (TP), *False Positive* (FP), *False Negative* (FN), dan *True Negative* (TN) sebagaimana ditunjukkan pada Tabel 3.1.

Tabel 3.3 Confusion Matrix

	Aktual Positif	Aktual Negatif
Prediksi Positif	True Positive (TP)	False Positive (FP)
Prediksi Negatif	False Negative (FN)	True Negative (TN)

Berdasarkan *confusion matrix* tersebut, dihitung metrik evaluasi berupa *accuracy*, *precision*, *recall*, dan *F1-score*. Mengingat penelitian ini melibatkan klasifikasi multikelas, metrik utama yang digunakan adalah *accuracy* dan *macro F1-score*, yaitu rata-rata *F1-score* seluruh kelas yang memberi bobot setara pada setiap kelas tanpa mempertimbangkan jumlah sampelnya. Penggunaan *macro F1-score* bertujuan untuk memberikan gambaran performa yang adil terhadap kelas dengan jumlah sampel lebih sedikit. Selain metrik agregat tersebut, nilai F1 pada setiap kelas ditelaah secara terpisah untuk mengetahui pada kelas mana perbaikan akibat distilasi terjadi, sebab perbaikan yang terkonsentrasi pada kelas-kelas yang saling menyerupai merupakan indikasi berpindahnya informasi kemiripan antarkelas dari guru ke student.

3.7.9 Uji Statistik

Untuk memastikan bahwa perbedaan performa antarskenario tidak terjadi secara kebetulan, dilakukan pengujian signifikansi statistik. Penelitian ini menggunakan dua jenis uji yang saling melengkapi. Pertama, uji berpasangan antar-*seed* berupa *paired t-test* dan *Wilcoxon signed-rank test* yang membandingkan akurasi lima *seed* pada dua skenario yang identik kecuali pada satu faktor. Kedua,

McNemar test dengan koreksi kontinuitas yang membandingkan pola benar-salah pada tingkat sampel uji.

Penggunaan beberapa uji statistik sekaligus bertujuan untuk memperkuat keabsahan kesimpulan, sehingga suatu strategi distilasi dinyatakan unggul hanya apabila keunggulannya konsisten pada berbagai uji. Tingkat signifikansi yang digunakan adalah 0,05. Pendekatan pengujian statistik untuk membandingkan model klasifikasi ini sejalan dengan praktik yang dianjurkan dalam literatur (Dietterich, 1998; Demšar, 2006).

3.7.10 Skenario Pengujian

Dalam rangka melakukan validasi empiris terhadap efektivitas strategi distilasi, penelitian ini menerapkan mekanisme pengujian komparatif (*benchmarking*) dengan membandingkan beberapa skenario pelatihan model. Skenario dirancang di sepanjang kurva *capacity gap*, mulai dari *baseline* tanpa distilasi, distilasi dari guru besar, distilasi dari asisten menengah, hingga *self-distillation* dari guru berkapasitas sama. Seluruh skenario dilatih dan dievaluasi menggunakan dataset serta skema pembagian data yang identik. Ringkasan skenario pengujian disajikan pada Tabel 3.2.

Tabel 3.4 Skenario Pengujian Model

Kode	Model (Student)	Guru (Soft-label)	Peran dalam Penelitian
R1	EfficientNet-B4	- (Cross-Entropy)	Guru besar / batas atas
R2	Focus-RCNet	- (Cross-Entropy)	Asisten menengah
R3	WasteNet-128K	- (Cross-Entropy)	Baseline 128K
R4	WasteNet-128K	EfficientNet-B4	Direct KD (Hinton)
R5	WasteNet-128K	Focus-RCNet	TA-KD 128K
R6	WasteNet-256K	- (Cross-Entropy)	Baseline 256K
R7	WasteNet-256K	EfficientNet-B4	Direct KD (Hinton)
R8	WasteNet-256K	Focus-RCNet	TA-KD 256K (metode inti)
R9	WasteNet-256K	WasteNet-256K (gen. sebelumnya)	Self-distillation (BAN)
R10	WasteNet-128K	- (Cross-Entropy)	Ablasi komponen arsitektur 128K
R11	WasteNet-256K	- (Cross-Entropy)	Ablasi komponen arsitektur 256K

Setiap skenario distilasi dilatih pada dua skema label, yaitu K6 (enam kelas) dan K5 (lima kelas), serta diulang pada lima *seed*. Sebagai pembanding, setiap strategi distilasi (R4, R5, R7, dan R8) memiliki skenario kontrol berpasangan tanpa distilasi yang menonaktifkan komponen KD namun mempertahankan konfigurasi dan jadwal pelatihan yang identik, sehingga efek distilasi diukur sebagai selisih berpasangan terhadap kontrol tersebut. Perbandingan performa difokuskan pada *accuracy* dan *macro F1-score*, kemudian diuji signifikansinya menggunakan uji statistik berpasangan. Hasil dari skenario pengujian ini selanjutnya digunakan untuk menentukan strategi distilasi terbaik yang akan dibahas secara mendalam pada bab berikutnya.

Nilai hyperparameter distilasi hasil uji pendahuluan yang kemudian dibekukan dan dipakai pada seluruh eksperimen lima seed disajikan pada Tabel 3.3. Skenario R10 dan R11 tidak dicantumkan karena keduanya dilatih dengan cross-entropy sehingga tidak memiliki parameter distilasi.

Tabel 3.5 Nilai hyperparameter distilasi hasil uji pendahuluan

Skenario	T (K6)	α (K6)	T (K5)	α (K5)	Laju pembelajaran
R4 - distilasi langsung 128K	2	0,3	2	0,3	0,05
R5 - TA-KD 128K	4	0,5	4	0,5	1×10^{-5}
R7 - distilasi langsung 256K	2	0,1	2	0,3	0,03
R8 - TA-KD 256K	4	0,5	4	0,5	1×10^{-4}
R9 - self-distillation 256K	2	0,3	4	0,1	0,03

Selain kesembilan skenario distilasi tersebut, dilakukan pula ablasi komponen arsitektur pada kedua varian student, yaitu R10 untuk WasteNet-128K dan R11 untuk WasteNet-256K. Ablasi ini bertujuan mengetahui komponen rancangan mana yang paling menentukan akurasi. Komponen yang divariasikan meliputi fungsi aktivasi, expand ratio pada blok inverted residual, koneksi residual, dan lapisan tersembunyi pada pengklasifikasi. Koneksi residual hanya diablasi pada varian 256K, sebab pada varian 128K tidak terdapat blok dengan dimensi masukan dan keluaran yang sama sehingga koneksi tersebut tidak pernah aktif.

Ablasi dijalankan pada skema K6 saja, sebab arsitektur WasteNet identik pada kedua skema label dan hanya berbeda pada jumlah neuron keluarannya sehingga kepentingan relatif antarkomponen tidak berubah. Setiap varian terdiri atas empat konfigurasi, yaitu baseline yang dilatih ulang beserta tiga variasi komponen, dan masing-masing dijalankan dengan lima seed menggunakan pengaturan pelatihan yang identik dengan baseline cross-entropy, sehingga seluruhnya berjumlah 40 kali pelatihan. Perlu dicatat bahwa variasi expand ratio dan lapisan tersembunyi mengubah jumlah parameter, sehingga jumlah parameter setiap konfigurasi dilaporkan bersama akurasinya agar pengaruh komponen tidak tertukar dengan pengaruh berkurangnya kapasitas.


BAB 4

HASIL DAN PEMBAHASAN

4.1 Hasil Penerapan Protokol Data

Penerapan protokol data menghasilkan pembagian 2.521 citra TrashNet menjadi 1.764 citra latih, 378 citra validasi, dan 379 citra uji, atau setara dengan proporsi 70:15:15. Pembagian dilakukan secara terstratifikasi sehingga komposisi kelas pada ketiga subset tetap sebanding dengan komposisi keseluruhan data. Setiap seed menghasilkan partisi yang berbeda, sehingga lima seed yang digunakan pada penelitian ini menghasilkan lima partisi yang saling independen.

Seluruh skenario yang diuji menggunakan partisi yang sama pada setiap seed. Dengan demikian perbandingan antarskenario dapat dilakukan secara berpasangan, yaitu membandingkan hasil pada seed yang sama, sehingga keragaman yang bersumber dari perbedaan pembagian data tidak tercampur dengan perbedaan yang berasal dari metode. Hal ini menjadi dasar penggunaan uji berpasangan pada subbab 4.4. Skema label K6 menggunakan enam kelas asli TrashNet, sedangkan skema K5 menghilangkan kelas trash dengan protokol yang identik pada aspek lainnya. Adapun distribusi jumlah citra pada setiap kelas dan subset data disajikan pada Gambar 4.1.



Gambar 4.9 Distribusi Jumlah Citra per Kelas dan per Subset Data

4.2 Kinerja Model Guru, Asisten, dan Baseline Student

Sebelum membahas pengaruh distilasi, terlebih dahulu disajikan kinerja masing-masing peran model yang menjadi acuan pada seluruh perbandingan berikutnya. Hasil selengkapnya disajikan pada Tabel 4.1.

Tabel 4.6 Kinerja model guru, asisten, dan baseline student

Model	Peran	Parameter	Akurasi K6	Akurasi K5
EfficientNet-B4	Guru besar	17,56 juta	0,9446 ±	0,9581 ±

Model	Peran	Parameter	Akurasi K6	Akurasi K5
			0,0070	0,0048
Focus-RCNet	Asisten menengah	520,6 ribu	$0,8507 \pm 0,0164$	$0,8737 \pm 0,0152$
WasteNet-256K	Student, CE	256,0 ribu	$0,7784 \pm 0,0128$	$0,7994 \pm 0,0259$
WasteNet-128K	Student, CE	128,1 ribu	$0,7652 \pm 0,0204$	$0,8067 \pm 0,0200$

Guru besar EfficientNet-B4 mencapai akurasi 0,9446 pada skema K6 dan menjadi batas atas kinerja pada penelitian ini, sedangkan asisten Focus-RCNet mencapai 0,8507 dengan jumlah parameter sekitar 34 kali lebih kecil. Adapun student WasteNet yang dilatih dengan cross-entropy memperoleh 0,7652 pada varian 128K dan 0,7784 pada varian 256K. Selisih antara guru besar dan kedua varian student berkisar antara 16,6 hingga 17,9 poin persentase, yang menunjukkan lebarnya jarak kapasitas antara keduanya.

Hal yang perlu dicatat adalah urutan kedua varian student tidak konsisten pada kedua skema label. Pada K6 varian 256K lebih unggul 1,3 poin persentase dari varian 128K, tetapi pada K5 justru varian 128K yang lebih tinggi, yaitu 0,8067 berbanding 0,7994, dengan simpangan baku varian 256K yang relatif besar. Dengan demikian penambahan kapasitas student dari 128K ke 256K belum tentu meningkatkan akurasi apabila pelatihan hanya menggunakan cross-entropy biasa.

Karena asisten berperan sebagai sumber pengetahuan pada skema TA-KD, cara pelatihan asisten juga diuji terlebih dahulu agar pemilihannya dapat dipertanggungjawabkan. Hasilnya disajikan pada Tabel 4.2.

Tabel 4.7 Pengaruh cara pelatihan asisten Focus-RCNet terhadap akurasinya

Cara pelatihan asisten	Akurasi K6	Δ K6 (p)	Akurasi K5	Δ K5 (p)
Cross-entropy	$0,8507 \pm 0,0164$	—	$0,8737 \pm 0,0152$	—
Distilasi langsung	$0,8554 \pm 0,0231$	+0,47 (0,62)	$0,8732 \pm 0,0135$	-0,06 (0,97)
Distilasi dua tahap	$0,8528 \pm 0,0078$	+0,21 (0,77)	$0,8765 \pm 0,0096$	+0,28 (0,77)


Tidak satu pun varian pelatihan asisten menghasilkan perbedaan yang signifikan terhadap pelatihan cross-entropy, baik pada K6 maupun K5. Oleh karena itu asisten yang dilatih dengan cross-entropy digunakan sebagai guru pada seluruh skenario TA-KD. Temuan ini sekaligus memberikan petunjuk awal yang penting, yaitu bahwa jadwal pelatihan dua tahap tidak dengan sendirinya memperbaiki hasil apabila guru yang digunakan tetap EfficientNet-B4.

4.3 Pengaruh Strategi Distilasi terhadap Kinerja Student

Bagian ini membandingkan seluruh strategi distilasi yang diterapkan pada student WasteNet. Rangkuman akurasi setiap skenario disajikan pada Tabel 4.3 dan divisualkan pada Gambar 4.2, sedangkan pengujian signifikansinya dibahas pada subbab 4.4.

Tabel 4.8 Perbandingan akurasi seluruh skenario pelatihan student

Skenario	Guru	Jadwal	Akurasi K6	Akurasi K5
WasteNet-128K, CE	—	Satu tahap	$0,7652 \pm 0,0204$	$0,8067 \pm 0,0200$
WasteNet-128K, distilasi langsung	EfficientNet-B4	Satu tahap	$0,7646 \pm 0,0127$	$0,8061 \pm 0,0181$
WasteNet-128K, TA-KD	Focus-RCNet	Dua tahap	$0,7578 \pm 0,0322$	$0,8117 \pm 0,0200$
WasteNet-256K, CE	—	Satu tahap	$0,7784 \pm 0,0128$	$0,7994 \pm 0,0259$
WasteNet-256K, distilasi langsung	EfficientNet-B4	Satu tahap	$0,7736 \pm 0,0178$	$0,8056 \pm 0,0156$
WasteNet-256K, TA-KD	Focus-RCNet	Dua tahap	$0,7873 \pm 0,0089$	$0,8235 \pm 0,0107$
WasteNet-256K, self-distillation	WasteNet-256K	Satu tahap	$0,7831 \pm 0,0105$	$0,8134 \pm 0,0109$



Gambar 4.10 Akurasi Student pada Seluruh Skenario Pelatihan beserta Simpangan Bakunya

4.3.1 Distilasi Langsung dari Guru Besar

Distilasi langsung dari EfficientNet-B4 tidak memberikan perbaikan pada kedua varian student. Pada WasteNet-128K akurasi justru bergerak dari 0,7652 menjadi 0,7646, sedangkan pada WasteNet-256K dari 0,7784 menjadi 0,7736. Kedua selisih tersebut sangat kecil dan tidak signifikan secara statistik. Pola yang

sama juga terlihat pada skema K5, sehingga kegagalan ini bukan merupakan akibat dari pemilihan skema label tertentu.

Hasil tersebut sejalan dengan temuan Cho dan Hariharan (2019) mengenai capacity gap, yaitu bahwa guru yang terlalu besar tidak selalu menghasilkan student yang lebih baik. Dengan selisih kapasitas sekitar 69 kali antara EfficientNet-B4 dan WasteNet-256K, distribusi keluaran guru diduga terlalu tajam dan terlalu kompleks untuk dapat ditiru oleh student yang sangat kecil.

4.3.2 Distilasi melalui Teacher Assistant

Berbeda dengan distilasi langsung, penggunaan asisten berkapasitas menengah memberikan hasil yang bergantung pada kapasitas student. Pada WasteNet-128K, skema TA-KD menghasilkan 0,7578 pada K6 dan tidak lebih baik dari kontrolnya. Sebaliknya, pada WasteNet-256K skema TA-KD menghasilkan 0,7873 pada K6 dan 0,8235 pada K5, yang merupakan akurasi tertinggi di antara seluruh skenario student pada kedua skema label.

Perlu ditegaskan bahwa pembandingan yang digunakan untuk menilai efek distilasi bukanlah baseline cross-entropy satu tahap, melainkan kontrol berpasangan yang menggunakan jadwal dua tahap yang sama dengan distilasi dimatikan. Dengan pembandingan tersebut, satu-satunya faktor yang berbeda adalah ada atau tidaknya transfer pengetahuan dari asisten, sehingga perbaikan yang terukur tidak dapat dikaitkan dengan perbedaan jadwal pelatihan. Kurva loss dan akurasi selama pelatihan skema tersebut disajikan pada Gambar 4.3.



Gambar 4.11 Kurva Loss dan Akurasi Pelatihan Skema TA-KD pada WasteNet-256K

4.3.3 Self-Distillation dengan Born-Again Networks

Skema self-distillation menggunakan guru berupa WasteNet-256K generasi sebelumnya, yaitu model dengan arsitektur dan kapasitas yang persis sama dengan student. Skema ini menghasilkan 0,7831 pada K6 dan 0,8134 pada K5. Kedua nilai tersebut berada di atas baseline cross-entropy, namun tetap lebih rendah daripada skema TA-KD dan tidak mencapai taraf signifikansi pada kedua skema label.

Meskipun demikian, terdapat gejala yang layak dicatat, yaitu menurunnya keragaman antarseed pada skema K5, dari simpangan baku 0,0259 pada baseline menjadi 0,0109. Hal ini sejalan dengan penjelasan Furlanello dkk. (2018) bahwa sebagian manfaat self-distillation berasal dari efek regularisasi soft label yang menghaluskan target pelatihan, bukan semata-mata dari transfer pengetahuan baru.

4.4 Hasil Uji Signifikansi Statistik

Setiap skema distilasi diuji terhadap kontrol berpasangannya, yaitu skenario yang identik kecuali pada satu faktor yang diuji. Pengujian dilakukan menggunakan uji t berpasangan antarseed dan dikonfirmasi dengan uji McNemar pada tingkat sampel. Hasil selengkapnya disajikan pada Tabel 4.4.

Tabel 4.9 Hasil uji berpasangan setiap skema distilasi terhadap kontrolnya

Perbandingan	Faktor yang diuji	K6: Δ , p, menang	K5: Δ , p, menang
Distilasi langsung, 128K	Distilasi vs tanpa distilasi	-0,05 pp; 0,94; 2/5	-0,06 pp; 0,96; 3/5
TA-KD, 128K	Asisten vs kontrol CE	-0,74 pp; 0,20; 1/5	-0,50 pp; 0,23; 1/5
Distilasi langsung, 256K	Distilasi vs tanpa distilasi	-0,47 pp; 0,68; 3/5	+0,61 pp; 0,68; 4/5
TA-KD, 256K	Asisten vs kontrol CE	+1,00 pp; 0,024; 5/5	+1,40 pp; 0,045; 5/5
Self-distillation, 256K	Guru diri sendiri vs tanpa distilasi	+0,47 pp; 0,51; 3/5	+1,40 pp; 0,38; 4/5

Dari seluruh perbandingan, hanya skema TA-KD pada WasteNet-256K yang mencapai taraf signifikansi. Skema tersebut unggul pada kelima seed di kedua skema label, dengan peningkatan 1,00 poin persentase pada K6 dengan p sebesar 0,024 dan 1,40 poin persentase pada K5 dengan p sebesar 0,045. Konsistensi kemenangan pada seluruh seed memperkuat kesimpulan bahwa perbaikan tersebut bukan kebetulan akibat satu partisi data tertentu.

Konfirmasi melalui uji McNemar memberikan gambaran yang perlu disampaikan secara berimbang. Pada skema K5 hasilnya signifikan dengan nilai khi-kuadrat 6,06 dan p sebesar 0,014, sedangkan pada skema K6 hasilnya mendekati taraf signifikansi dengan nilai khi-kuadrat 2,97 dan p sebesar 0,085. Perbedaan ini wajar karena kedua uji memandang data dari sudut yang berbeda, yaitu uji t berpasangan bekerja pada tingkat seed sedangkan uji McNemar bekerja pada tingkat sampel. Dengan demikian bukti terkuat berada pada skema K5, sementara pada skema K6 arah perbaikannya konsisten namun dukungan statistiknya lebih lemah.

Uji Wilcoxon signed-rank memberikan hasil yang searah namun perlu dibaca dengan memperhatikan keterbatasannya. Pada skema TA-KD WasteNet-256K nilai p yang diperoleh adalah 0,062 untuk kedua skema label, sedangkan skema lainnya berkisar antara 0,273 hingga 1,000. Perlu dipahami bahwa dengan lima seed, nilai

p dua sisi terkecil yang mungkin dihasilkan uji Wilcoxon adalah 0,0625, yaitu ketika seluruh pasangan bergerak searah. Dengan demikian nilai 0,062 pada skema TA-KD merupakan hasil terkuat yang dapat dicapai uji tersebut pada jumlah seed ini, dan angka itu muncul justru karena skema tersebut unggul pada kelima seed. Uji Wilcoxon di sini berfungsi memastikan arah dan konsistensi perbaikan, bukan menetapkan taraf signifikansi, sebab resolusinya memang terbatas pada ukuran sampel sekecil ini.

Seluruh skema lainnya tidak signifikan pada semua uji yang digunakan. Skema self-distillation menunjukkan arah perbaikan yang positif pada kedua skema label, tetapi besarnya perbaikan tidak konsisten antarseed sehingga tidak pernah mencapai taraf signifikansi.


4.5 Analisis Kinerja per Kelas

Untuk mengetahui letak perbaikan yang dihasilkan distilasi, dilakukan penelaahan terhadap nilai F1 setiap kelas. Selisih F1 antara skema TA-KD dan kontrolnya disajikan pada Tabel 4.5.

Tabel 4.10 Selisih F1 per kelas pada skema TA-KD terhadap kontrolnya


Kelas	F1 TA-KD (K6)	F1 kontrol (K6)	$\Delta F1$ K6 (pp)	$\Delta F1$ K5 (pp)
glass	0,731	0,708	+2,23	+1,98
metal	0,742	0,725	+1,68	+0,68
paper	0,863	0,855	+0,82	+1,23
cardboard	0,901	0,895	+0,58	+0,69
plastic	0,754	0,751	+0,33	+2,34
trash	0,561	0,572	-1,03	—

Perbaikan tidak tersebar merata, melainkan terkonsentrasi pada kelas-kelas yang paling sulit dibedakan, yaitu glass dan metal pada skema K6 serta plastic dan glass pada skema K5. Ketiga kelas tersebut merupakan kelompok sampah daur ulang yang secara visual saling menyerupai. Pola ini konsisten dengan gagasan dark knowledge, yaitu bahwa manfaat distilasi berasal dari informasi kemiripan antarkelas yang terkandung pada distribusi keluaran guru, bukan sekadar dari efek penghalusan target. Sebaran selisih F1 pada kedua skema label tersebut divisualkan pada Gambar 4.4.



Gambar 4.12 Perbandingan Selisih F1 per Kelas pada Skema TA-KD antara Skema K6 dan K5

Sebaliknya, kelas trash pada skema K6 justru mengalami penurunan sebesar 1,03 poin persentase. Kelas ini bersifat heterogen dan berjumlah paling sedikit, sehingga struktur kemiripan yang ditawarkan guru kurang bermakna. Hal tersebut sekaligus menjelaskan mengapa perbaikan pada skema K5 yang tidak memuat kelas trash terlihat lebih besar dan lebih bersih. Pola kesalahan klasifikasi kedua skema dapat diamati pada Gambar 4.5, yang memperlihatkan bahwa kekeliruan terbanyak memang terjadi di antara kelas glass, metal, dan plastic.



Gambar 4.13 Confusion Matrix Data Uji (kiri: kontrol cross-entropy, kanan: TA-KD)

Penelaahan yang sama dilakukan pada skema self-distillation dan hasilnya disajikan pada Tabel 4.6.

Tabel 4.11 Selisih F1 per kelas pada skema self-distillation terhadap baseline

Kelas	F1 self-KD (K6)	F1 baseline (K6)	$\Delta F1$ K6 (pp)	$\Delta F1$ K5 (pp)
glass	0,750	0,712	+3,77	+1,87
trash	0,603	0,589	+1,45	—
metal	0,727	0,717	+1,05	+2,09
cardboard	0,887	0,893	-0,58	+2,60
paper	0,854	0,860	-0,60	+1,95
plastic	0,744	0,756	-1,22	-1,44

Skema self-distillation sebagian meniru pola yang sama, terlihat dari naiknya kelas glass dan metal pada kedua skema label. Akan tetapi perbaikannya kurang terarah. Kelas plastic yang menjadi penerima manfaat terbesar pada skema TA-KD justru menurun pada kedua skema label, sedangkan kelas trash pada skema K6 bergerak berlawanan arah dibandingkan skema TA-KD. Temuan ini menunjukkan bahwa guru berkapasitas sama membawa informasi kemiripan antarkelas yang lebih lemah dan kurang terfokus dibandingkan asisten berkapasitas menengah, dan hal tersebut menjelaskan mengapa perbaikannya tidak mencapai taraf signifikansi meskipun arahnya positif.

4.6 Perbandingan Skema Lima Kelas dan Enam Kelas

Pada seluruh skenario, skema K5 menghasilkan akurasi yang lebih tinggi daripada skema K6, dengan selisih berkisar antara 1,3 hingga 5,4 poin persentase. Selisih pada nilai macro F1 bahkan lebih besar karena kelas trash yang sulit dikenali ikut menekan rata-rata F1 pada skema K6. Perbandingan ini bersifat deskriptif dan tidak diuji secara berpasangan, sebab kedua skema bekerja pada ruang label yang berbeda sehingga jumlah kelas dan tingkat kesulitan tugasnya tidak setara.

Nilai penting dari perbandingan ini terletak pada konsistensi temuan. Skema TA-KD pada WasteNet-256K unggul pada kelima seed di kedua skema label, sehingga keunggulannya tidak bergantung pada ada atau tidaknya kelas trash. Sebaliknya, seluruh skema yang tidak signifikan pada skema K6 juga tidak signifikan pada skema K5. Kesesuaian arah temuan pada dua ruang label yang berbeda memperkuat keandalan kesimpulan penelitian ini.

4.7 Efisiensi Komputasi Model Student

Selain akurasi, kelayakan penerapan model juga dinilai dari kebutuhan komputasinya. Perbandingan jumlah parameter, FLOPs, dan akurasi setiap varian student disajikan pada Tabel 4.7.

Tabel 4.12 Efisiensi komputasi model student pada resolusi masukan 160×160 piksel

Model student	Parameter	FLOPs	Akurasi K6
WasteNet-128K, CE	128.086	≈ 51 juta	$0,7652 \pm 0,0204$
WasteNet-256K, CE	256.002	≈ 84 juta	$0,7784 \pm 0,0128$
WasteNet-256K, TA-KD	256.002	≈ 84 juta	$0,7873 \pm 0,0089$

Perlu diperhatikan bahwa skema TA-KD meningkatkan akurasi tanpa menambah satu pun parameter maupun operasi komputasi, sebab distilasi hanya mengubah cara model dilatih dan tidak mengubah arsitekturnya. Perbaikan sebesar 1,00 poin persentase pada skema K6 dan 1,40 poin persentase pada skema K5 diperoleh dengan biaya inferensi yang sama persis, sehingga tergolong perbaikan yang murah dari sudut pandang penerapan.

Apabila dibandingkan dengan guru besarnya, model WasteNet-256K hasil TA-KD memiliki parameter sekitar 69 kali lebih sedikit daripada EfficientNet-B4, namun tetap mempertahankan sekitar 83 persen dari akurasi guru tersebut. Dengan beban komputasi sekitar 84 juta FLOPs, model ini sesuai untuk diterapkan pada perangkat dengan sumber daya terbatas.

4.8 Ablasi Komponen Arsitektur

Bagian ini menelaah komponen arsitektur mana yang paling menentukan akurasi WasteNet. Pengujian dilakukan pada skema K6 saja, sebab arsitektur WasteNet identik pada kedua skema label dan hanya berbeda pada jumlah neuron keluarannya, sehingga kepentingan relatif antarkomponen tidak berubah. Setiap konfigurasi dilatih ulang menggunakan lima seed dengan pengaturan pelatihan yang identik dengan baseline cross-entropy, sehingga seluruh pengujian pada bagian ini mencakup 40 kali pelatihan.

Komponen yang divariasikan meliputi fungsi aktivasi, expand ratio pada blok inverted residual, koneksi residual, dan lapisan tersembunyi pada pengklasifikasi. Koneksi residual hanya diablasikan pada varian 256K, sebab pada varian 128K tidak terdapat blok dengan dimensi masukan dan keluaran yang sama sehingga koneksi residual memang tidak pernah aktif dan ablasinya tidak akan berpengaruh. Perlu ditegaskan pula bahwa variasi expand ratio dan lapisan tersembunyi mengubah jumlah parameter, sehingga efek yang terukur bercampur antara hilangnya komponen dan berkurangnya kapasitas. Oleh karena itu jumlah parameter dicantumkan pada setiap baris, sedangkan variasi fungsi aktivasi dan koneksi residual tidak mengubah jumlah parameter sehingga efeknya dapat dibaca secara langsung. Hasil ablasi pada varian 128K disajikan pada Tabel 4.8 dan pada varian 256K pada Tabel 4.9.

Tabel 4.13 Hasil ablasi komponen arsitektur pada WasteNet-128K

Konfigurasi	Akurasi	Δ vs baseline	p	Parameter
Baseline	$0,7689 \pm 0,0172$	—	—	128.086
Aktivasi SiLU menjadi ReLU	$0,7156 \pm 0,0193$	-5,33 pp	0,004	128.086
Expand ratio 2,0 menjadi 1,0	$0,7689 \pm 0,0198$	+0,00 pp	1,000	45.638
Tanpa lapisan	$0,7646 \pm 0,0192$	-0,42 pp	0,634	122.870

Konfigurasi	Akurasi	Δ vs baseline	p	Parameter
tersembunyi				

Tabel 4.14 Hasil ablasi komponen arsitektur pada WasteNet-256K

Konfigurasi	Akurasi	Δ vs baseline	p	Parameter
Baseline	$0,7694 \pm 0,0164$	—	—	256.002
Aktivasi SiLU menjadi ReLU	$0,7873 \pm 0,0223$	+1,79 pp	0,268	256.002
Tanpa koneksi residual	$0,7662 \pm 0,0130$	-0,32 pp	0,702	256.002
Expand ratio 2,5 menjadi 1,0	$0,7689 \pm 0,0091$	-0,05 pp	0,918	64.206


Pada varian 128K, fungsi aktivasi merupakan satu-satunya komponen yang berpengaruh secara signifikan. Penggantian SiLU dengan ReLU menurunkan akurasi sebesar 5,33 poin persentase dengan p sebesar 0,004, dan penurunan tersebut terjadi secara konsisten pada kelima seed. Karena penggantian ini tidak mengubah jumlah parameter sama sekali, penurunan tersebut murni berasal dari perubahan fungsi aktivasi dan bukan dari berkurangnya kapasitas model.

Keadaan yang berbeda ditemukan pada varian 256K. Pada varian tersebut tidak ada satu pun komponen yang menghasilkan perbedaan signifikan, sebab seluruh nilai p berada di atas 0,26. Penggantian ke ReLU memang menaikkan akurasi sebesar 1,79 poin persentase, tetapi kenaikan tersebut tidak signifikan sehingga belum dapat dinyatakan sebagai perbaikan yang meyakinkan. Dengan demikian arsitektur WasteNet-256K tergolong tahan terhadap perubahan komponen penyusunnya.

Perbedaan antara kedua varian menunjukkan bahwa pengaruh fungsi aktivasi bergantung pada kapasitas model. Ketika kapasitas terbatas seperti pada varian 128K, pemilihan fungsi aktivasi menjadi menentukan, sedangkan pada varian 256K perbedaannya menghilang. Hal ini diduga karena kapasitas yang lebih besar menyediakan cukup keleluasaan sehingga model tidak lagi bergantung pada satu fungsi aktivasi tertentu. Pola ini sejalan dengan temuan pada subbab sebelumnya bahwa kapasitas student turut menentukan bagaimana model merespons perlakuan yang diberikan kepadanya.

Temuan lain berkaitan dengan expand ratio. Penurunan expand ratio memangkas 64 hingga 75 persen jumlah parameter, tetapi akurasinya hampir tidak berubah dengan nilai p paling rendah sebesar 0,92. Hal ini menunjukkan bahwa kapasitas pada dimensi expand cenderung berlebih, sehingga masih tersedia ruang untuk penghematan parameter tanpa mengorbankan akurasi. Temuan ini bermanfaat sebagai arah pengembangan lanjutan, meskipun perlu dibaca dengan hati-hati karena variasi tersebut termasuk variasi yang mengubah jumlah parameter.

Perbandingan akurasi seluruh konfigurasi ablasi pada kedua varian disajikan pada Gambar 4.6.



Gambar 4.14 Hasil Ablasi Komponen Arsitektur pada Kedua Varian WasteNet

Hasil ablasi ini memberikan dukungan tidak langsung terhadap kesimpulan utama penelitian. Karena arsitektur WasteNet-256K terbukti tahan terhadap perubahan komponen penyusunnya, peningkatan akurasi sebesar 1,00 poin persentase yang diperoleh melalui skema TA-KD tidak dapat dijelaskan oleh kekhususan rancangan arsitektur, melainkan berasal dari cara model tersebut dilatih. Perlu dicatat pula bahwa penggunaan lima seed membatasi daya uji, sehingga sebagian selisih yang kecil pada varian 256K berpotensi tidak terdeteksi meskipun sebenarnya nyata.

4.9 Perbandingan dengan Penelitian Terdahulu

Bagian ini menempatkan hasil penelitian terhadap penelitian terdahulu yang menggunakan dataset TrashNet. Angka penelitian terdahulu dikutip dari Zheng dkk. (2023) yang melaporkan perbandingan beberapa arsitektur pada dataset yang sama, sedangkan angka penelitian ini diambil dari skema enam kelas agar sebanding dengan jumlah kelas yang digunakan pada penelitian tersebut. Perbandingan selengkapnya disajikan pada Tabel 4.10.

Tabel 4.15 Perbandingan dengan penelitian terdahulu pada dataset TrashNet

Model	Sumber	Akurasi	Parameter	FLOPs
ResNet50	Zheng dkk. (2023)	0,87	25,560 juta	12,087 G
DenseNet121	Zheng dkk. (2023)	0,88	6,960 juta	8,121 G
MobileNetV1	Zheng dkk. (2023)	0,85	2,232 juta	0,952 G
ShuffleNetV1	Zheng dkk. (2023)	0,86	0,348 juta	0,127 G

Model	Sumber	Akurasi	Parameter	FLOPs
EfficientNet-B4	Zheng dkk. (2023)	0,97	17,559 juta	4,490 G
Focus-RCNet + KD	Zheng dkk. (2023)	0,92	0,526 juta	0,419 G
EfficientNet-B4	Penelitian ini	0,9446	17,56 juta	—
Focus-RCNet	Penelitian ini	0,8507	0,521 juta	—
WasteNet-256K, TA-KD	Penelitian ini	0,7873	0,256 juta	0,084 G
WasteNet-128K, CE	Penelitian ini	0,7652	0,128 juta	0,051 G

Dari sisi efisiensi, model usulan penelitian ini berada pada tingkat yang lebih hemat daripada seluruh model pembandingan. WasteNet-256K hanya memerlukan 0,256 juta parameter dan sekitar 0,084 G FLOPs, yaitu kurang dari separuh parameter dan sekitar lima kali lebih sedikit beban komputasi dibandingkan Focus-RCNet. Bahkan terhadap model pembandingan yang paling ringan, yaitu ShuffleNetV1 dengan 0,348 juta parameter dan 0,127 G FLOPs, model usulan tetap lebih kecil. Dengan demikian penelitian ini bekerja pada rentang kapasitas yang lebih rendah daripada seluruh penelitian pembandingan tersebut.

Dari sisi akurasi, model usulan berada di bawah penelitian terdahulu. Focus-RCNet melaporkan akurasi 0,92, sedangkan WasteNet-256K hasil TA-KD mencapai 0,7873. Perbedaan ini perlu dibaca secara hati-hati karena dua hal. Pertama, terdapat perbedaan kelas kapasitas yang besar, sebab model usulan dirancang pada rentang 128 ribu hingga 256 ribu parameter yang tidak dijangkau oleh model pembandingan mana pun. Kedua, protokol evaluasinya berbeda. Zheng dkk. (2023) memperbesar dataset melalui augmentasi dan melaporkan satu angka hasil pengujian, sedangkan penelitian ini mempertahankan ukuran dataset asli sebanyak 2.521 citra dan melaporkan rata-rata lima seed dengan pembagian data yang berbeda pada setiap seed. Protokol yang kedua cenderung menghasilkan angka yang lebih rendah namun lebih konservatif.

Indikasi perbedaan protokol tersebut juga terlihat pada model pembandingan yang diimplementasikan dalam penelitian ini. Focus-RCNet yang dilatih ulang menggunakan protokol penelitian ini mencapai 0,8507, lebih rendah daripada 0,92 yang dilaporkan penulis aslinya, sedangkan EfficientNet-B4 mencapai 0,9446 dibandingkan 0,97. Selisih yang muncul pada kedua model tersebut menunjukkan bahwa perbedaan angka lebih banyak bersumber dari protokol evaluasi daripada dari implementasi modelnya, sehingga perbandingan langsung antarangka mentah tidak sepenuhnya setara.


Perlu ditegaskan bahwa tujuan penelitian ini bukan mengejar akurasi tertinggi pada dataset TrashNet, melainkan menganalisis pengaruh kapasitas guru terhadap keberhasilan knowledge distillation pada student yang sangat kecil. Penelitian terdahulu umumnya berhenti pada kapasitas ratusan ribu hingga jutaan parameter

dan tidak menguji bagaimana pemilihan guru memengaruhi student pada rentang di bawahnya. Pada rentang tersebut penelitian ini menunjukkan bahwa pemilihan guru berkapasitas menengah dapat meningkatkan akurasi secara signifikan tanpa menambah satu pun parameter, sehingga kontribusinya bersifat melengkapi dan bukan menggantikan penelitian terdahulu.

4.10 Pembahasan

Rangkaian hasil di atas menunjukkan bahwa keberhasilan distilasi pada penelitian ini ditentukan oleh kapasitas guru, bukan oleh jadwal pelatihan. Ketika guru yang digunakan adalah EfficientNet-B4, distilasi tidak memberikan perbaikan baik pada jadwal satu tahap maupun dua tahap. Sebaliknya, ketika guru diganti menjadi asisten berkapasitas menengah dengan jadwal yang sama, perbaikan yang signifikan baru muncul. Temuan ini mendukung skema teacher assistant yang diusulkan Mirzadeh dkk. (2020) sebagai cara mengatasi capacity gap.

Apabila ketiga jenis guru diurutkan berdasarkan kapasitasnya, terbentuk pola yang runtut. Guru yang jauh lebih besar tidak memberikan perbaikan, guru yang berkapasitas sama dengan student memberikan arah perbaikan yang positif tetapi tidak signifikan, sedangkan guru berkapasitas menengah memberikan perbaikan yang signifikan dan konsisten. Dengan demikian guru yang efektif bukanlah guru yang paling kuat, melainkan guru yang jarak kapasitasnya terhadap student tidak terlalu jauh dan tidak terlalu dekat. Pola tersebut divisualkan pada Gambar 4.7.



Gambar 4.15 Perubahan Akurasi Student menurut Kapasitas Guru

Selain kapasitas guru, kapasitas student juga turut menentukan. Skema TA-KD tidak memberikan perbaikan pada WasteNet-128K, tetapi berhasil pada

WasteNet-256K. Hal ini menunjukkan bahwa student memerlukan kapasitas yang memadai untuk dapat menampung pengetahuan yang ditransfer. Pada model yang terlalu kecil, kapasitas diduga telah habis terpakai untuk mempelajari tugas dasarnya sehingga tidak tersisa ruang untuk memanfaatkan informasi tambahan dari guru. Dengan demikian keberhasilan distilasi ditentukan oleh kesesuaian kapasitas pada kedua sisi, yaitu sisi guru dan sisi student.

Analisis per kelas memberikan dukungan mekanistik terhadap kesimpulan tersebut. Perbaikan yang dihasilkan skema TA-KD terkonsentrasi pada kelompok kelas daur ulang yang saling menyerupai, sedangkan skema self-distillation menghasilkan perbaikan yang lebih menyebar dan kurang terarah. Perbedaan pola ini memperlihatkan bahwa yang berpindah dari asisten ke student bukan sekadar efek penghalusan target, melainkan informasi mengenai kemiripan antarkelas.

Penelitian ini juga memiliki sejumlah keterbatasan yang perlu dikemukakan. Jumlah data yang digunakan tergolong kecil, yaitu 2.521 citra, sehingga keragaman antartpartisi cukup besar. Jumlah seed sebanyak lima juga membatasi daya uji statistik, sehingga perbaikan yang kecil berpotensi tidak terdeteksi meskipun sebenarnya nyata. Selain itu besarnya perbaikan yang diperoleh berkisar pada satu poin persentase, sehingga penerapannya perlu mempertimbangkan kebutuhan ketelitian pada kasus penggunaan yang dituju.

BAB 5

PENUTUP

5.1 Simpulan

Berdasarkan hasil penelitian dan pembahasan mengenai penerapan knowledge distillation berbasis teacher assistant pada model ringan WasteNet untuk klasifikasi citra sampah TrashNet, dapat disimpulkan sebagai berikut:

1. Model ringan WasteNet berhasil dibangun dan dilatih menggunakan knowledge distillation dalam dua varian kapasitas, yaitu WasteNet-128K dengan 128.086 parameter dan beban komputasi sekitar 51 juta FLOPs, serta WasteNet-256K dengan 256.002 parameter dan sekitar 84 juta FLOPs pada resolusi masukan 160×160 piksel. Model terbaik diperoleh melalui skema teacher assistant pada varian WasteNet-256K dengan akurasi 0,7873 pada skema enam kelas dan 0,8235 pada skema lima kelas. Model tersebut memiliki jumlah parameter sekitar 69 kali lebih sedikit daripada guru besarnya, namun tetap mempertahankan sekitar 83 persen dari akurasi guru tersebut, sehingga layak diterapkan pada perangkat dengan sumber daya terbatas.
2. Kapasitas guru terbukti menentukan keberhasilan distilasi. Distilasi langsung dari guru besar EfficientNet-B4 tidak memberikan perbaikan, yaitu -0,05 poin persentase pada WasteNet-128K dan -0,47 poin persentase pada WasteNet-256K. Guru berkapasitas sama melalui skema self-distillation hanya menghasilkan perbaikan 0,47 poin persentase pada skema enam kelas dan 1,40 poin persentase pada skema lima kelas, dan keduanya tidak signifikan. Sebaliknya, asisten berkapasitas menengah Focus-RCNet menghasilkan perbaikan 1,00 poin persentase dan 1,40 poin persentase pada kedua skema label secara signifikan. Dengan demikian jenis guru yang paling efektif bukanlah guru yang paling besar, melainkan guru berkapasitas menengah yang jarak kapasitasnya terhadap student tidak terlalu jauh dan tidak terlalu dekat. Selain kapasitas guru, kapasitas student juga menentukan, sebab skema teacher assistant hanya berhasil pada WasteNet-256K dan tidak pada WasteNet-128K.
3. Evaluasi statistik terhadap kontrol berpasangan menunjukkan bahwa hanya skema teacher assistant pada WasteNet-256K yang mencapai taraf signifikansi, dengan nilai p sebesar 0,024 pada skema enam kelas dan 0,045 pada skema lima kelas, serta unggul pada kelima seed yang diuji. Konfirmasi melalui uji McNemar menghasilkan nilai khi-kuadrat 6,06 dengan p sebesar 0,014 pada skema lima kelas, sedangkan pada skema enam kelas nilainya 2,97 dengan p sebesar 0,085 sehingga baru mendekati taraf signifikansi. Seluruh skema distilasi lainnya tidak signifikan pada semua uji yang digunakan. Perbaikan yang dihasilkan terkonsentrasi pada kelas glass, metal, dan plastic yang secara visual saling menyerupai, sehingga

mendukung penjelasan bahwa manfaat distilasi berasal dari informasi kemiripan antarkelas.

4. Ablasi komponen arsitektur menunjukkan bahwa fungsi aktivasi merupakan komponen yang paling menentukan, namun pengaruhnya hanya signifikan pada varian berkapasitas kecil. Penggantian SiLU dengan ReLU menurunkan akurasi WasteNet-128K sebesar 5,33 poin persentase dengan p sebesar 0,004, sedangkan pada WasteNet-256K tidak ada satu pun komponen yang berpengaruh signifikan. Selain itu pemangkasan 64 hingga 75 persen parameter melalui penurunan expand ratio tidak menurunkan akurasi, yang menunjukkan bahwa dimensi tersebut masih berlebih.

5.2 Saran

Berdasarkan hasil penelitian ini, terdapat beberapa saran yang dapat menjadi bahan pertimbangan bagi penelitian selanjutnya:

1. Model yang dihasilkan perlu diuji secara langsung pada perangkat dengan sumber daya terbatas seperti Raspberry Pi, NVIDIA Jetson Nano, atau perangkat berbasis mikrokontroler. Pengujian tersebut diperlukan untuk mengukur latensi inferensi, penggunaan memori, dan konsumsi daya pada kondisi penerapan yang sebenarnya, sebab penelitian ini baru mengukur efisiensi secara analitis melalui jumlah parameter dan FLOPs.
2. Penelitian selanjutnya disarankan menggunakan data yang lebih banyak dan lebih beragam serta menambah jumlah seed yang diuji. Jumlah data pada penelitian ini sebanyak 2.521 citra dan jumlah seed sebanyak lima masih membatasi daya uji statistik, sehingga perbaikan yang kecil berpotensi tidak terdeteksi meskipun sebenarnya nyata.
3. Rentang kapasitas asisten perlu ditelusuri lebih lanjut. Penelitian ini baru menguji satu titik kapasitas asisten, yaitu Focus-RCNet dengan sekitar 520 ribu parameter, sehingga titik kapasitas yang benar-benar optimal pada kurva capacity gap belum diketahui. Pengujian beberapa asisten dengan kapasitas yang berbeda akan memperjelas bentuk kurva tersebut.
4. Skema teacher assistant yang digunakan pada penelitian ini perlu diterapkan pada arsitektur ringan lain seperti MobileNetV3, ShuffleNetV2, atau GhostNet. Pengujian lintas arsitektur diperlukan untuk mengetahui apakah temuan mengenai kapasitas guru bersifat umum atau khusus pada arsitektur WasteNet.
5. Temuan mengenai berlebihnya kapasitas pada dimensi expand dapat dimanfaatkan untuk merancang varian WasteNet yang lebih hemat parameter. Perancangan ulang tersebut berpotensi menghasilkan model dengan akurasi setara namun berukuran jauh lebih kecil.

DAFTAR PUSTAKA

- Buslaev, A., Iglovikov, V. I., Khvedchenya, E., Parinov, A., Druzhinin, M., & Kalinin, A. A. (2020). Albumentations: Fast and flexible image augmentations. *Information*, 11(2), 125. <https://doi.org/10.3390/info11020125>
- Chicco, D., & Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics*, 21(1), 6. <https://doi.org/10.1186/s12864-019-6413-7>
- Cho, J. H., & Hariharan, B. (2019). On the efficacy of knowledge distillation. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 4794–4802. <https://doi.org/10.1109/ICCV.2019.00489>
- Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7, 1–30.
- Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, 10(7), 1895–1923. <https://doi.org/10.1162/089976698300017197>
- Furlanello, T., Lipton, Z. C., Tschannen, M., Itti, L., & Anandkumar, A. (2018). Born-again neural networks. *Proceedings of the 35th International Conference on Machine Learning (ICML)*, PMLR 80, 1607–1616.
- Gonzalez, R. C., & Woods, R. E. (2018). *Digital image processing* (4th ed.). Pearson.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- Hinton, G., Vinyals, O., & Dean, J. (2015). Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*. <https://doi.org/10.48550/arXiv.1503.02531>
- Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). *MobileNets: Efficient convolutional neural networks for mobile vision applications*. *arXiv preprint arXiv:1704.04861*. <https://doi.org/10.48550/arXiv.1704.04861>
- Kaza, S., Yao, L. C., Bhada-Tata, P., & Van Woerden, F. (2018). *What a waste 2.0: A global snapshot of solid waste management to 2050*. World Bank. <https://doi.org/10.1596/978-1-4648-1329-0>
- Kementerian Lingkungan Hidup dan Kehutanan. (2023). *Sistem Informasi Pengelolaan Sampah Nasional (SIPSN): Capaian kinerja pengelolaan sampah*. <https://sipsn.menlhk.go.id/>
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems (NeurIPS)*, 25, 1097–1105.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>

- LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324. <https://doi.org/10.1109/5.726791>
- Mirzadeh, S. I., Farajtabar, M., Li, A., Levine, N., Matsukawa, A., & Ghasemzadeh, H. (2020). Improved knowledge distillation via teacher assistant. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34(04), 5191–5198. <https://doi.org/10.1609/aaai.v34i04.5963>
- Nair, V., & Hinton, G. E. (2010). Rectified linear units improve restricted Boltzmann machines. *Proceedings of the 27th International Conference on Machine Learning (ICML)*, 807–814.
- O'Shea, K., & Nash, R. (2015). An introduction to convolutional neural networks. *arXiv preprint arXiv:1511.08458*. <https://doi.org/10.48550/arXiv.1511.08458>
- Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), 1345–1359. <https://doi.org/10.1109/TKDE.2009.191>
- Perez, L., & Wang, J. (2017). The effectiveness of data augmentation in image classification using deep learning. *arXiv preprint arXiv:1712.04621*. <https://doi.org/10.48550/arXiv.1712.04621>
- Powers, D. M. W. (2011). Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63.
- Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M., Berg, A. C., & Fei-Fei, L. (2015). ImageNet large scale visual recognition challenge. *International Journal of Computer Vision*, 115(3), 211–252. <https://doi.org/10.1007/s11263-015-0816-y>
- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L.-C. (2018). MobileNetV2: Inverted residuals and linear bottlenecks. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 4510–4520. <https://doi.org/10.1109/CVPR.2018.00474>
- Schmidhuber, J. (2015). Deep learning in neural networks: An overview. *Neural Networks*, 61, 85–117. <https://doi.org/10.1016/j.neunet.2014.09.003>
- Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1), 60. <https://doi.org/10.1186/s40537-019-0197-0>
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427–437. <https://doi.org/10.1016/j.ipm.2009.03.002>
- Sugiyono. (2015). *Metode penelitian kuantitatif, kualitatif, dan R&D*. Alfabeta.
- Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, PMLR 97, 6105–6114.

- Thung, G., & Yang, M. (2016). *Classification of trash for recyclability status* [Laporan proyek CS229]. Stanford University.
- White, G., Cabrera, C., Palade, A., Li, F., & Clarke, S. (2020). *WasteNet: Waste classification at the edge for smart bins*. arXiv preprint arXiv:2006.05873. <https://doi.org/10.48550/arXiv.2006.05873>
- Zheng, D., Wang, R., Duan, Y., Pang, P. C., & Tan, T. (2023). Focus-RCNet: A lightweight recyclable waste classification algorithm based on focus and knowledge distillation. *Visual Computing for Industry, Biomedicine, and Art*, 6(1), Article 19. <https://doi.org/10.1186/s42492-023-00146-3>

LAMPIRAN



Penulis Bernama lengkap Hamza Pratama, lahir di Boyolali pada 20 November 2003. Penulis merupakan anak pertama dari pasangan Bapak Mochammad Yasin dan Ibu Ega Sri Sundari Legawati. Pendidikan dasar diselesaikan oleh penulis di SD Negeri Purwoyoso 01 Semarang, Jawa Tengah pada tahun 2016, kemudian melanjutkan ke SMP Negeri 18 Semarang, Jawa Tengah dan diselesaikan pada tahun 2019. Setelah itu penulis melanjutkan pendidikan di SMA Negeri 8 Semarang, Jawa Tengah dengan jurusan Ilmu Pengetahuan Alam (IPA) dan lulus pada tahun 2022.

Pada tahun 2022, penulis melanjutkan studi jenjang S1 di Universitas Negeri Semarang, tepatnya di Program Studi Teknik Informatika yang berada di bawah naungan Fakultas Matematika dan Ilmu Pengetahuan Alam (FMIPA). Selama masa perkuliahan, penulis aktif mengembangkan minat pada bidang *Machine Learning* dan *Web Development*. Penulis juga pernah berkesempatan magang sebagai *AI Engineer* di PT APLIKANUSA LINTASARTA.

Penulis menyadari bahwa penyusunan karya tulis ini masih memiliki banyak kekurangan. Oleh karena itu, saran dan kritik yang membangun sangat diharapkan untuk membantu penulis meningkatkan kualitas karya ini. Penulis dapat dihubungi melalui email hamzapratama000@gmail.com.